

Guia de Uso — IA Command

Configure e opere o IA Command: provedor de IA, conexão com ERP Protheus, canais WhatsApp, módulos de conhecimento, intenções, sinônimos, diálogos, pipeline Text-to-SQL dinâmico e auditoria completa. Leia em ordem pelas fases para um setup correto e sem retrabalho.

Arquitetura IA-first

Groq · OpenAI · Gemini · Claude

Text-to-SQL dinâmico

Multi-turn conversacional

Protheus SX2/SX3

Auditoria completa

1

Visão Geral

Entenda a arquitetura antes de configurar

1.1 O que é o IA Command

O **IA Command** transforma o ERP Protheus em uma conversa. O usuário envia perguntas livres pelo WhatsApp — "faturamento de abril por produto", "top clientes do trimestre", "contas a pagar vencidas" — e o sistema interpreta, consulta o ERP e responde em linguagem natural.

IA como provider primário

Todo pedido passa primeiro por um modelo de linguagem externo (Groq, OpenAI, Gemini, DeepSeek ou Claude Anthropic). O motor local existe apenas como último recurso quando não há chave ou a IA está indisponível.

Dois modos de consulta ERP

Datasets cadastrados: SQL fixo parametrizado para intenções simples registradas manualmente. **Text-to-SQL dinâmico:** a IA gera o SQL em tempo real para compras, faturamento, financeiro, comissão e estoque com base no esquema real do Protheus (SX2/SX3) — ver [6.1](#) para a ressalva sobre o estado do módulo Estoque.

Multi-turn conversacional

Contexto mantido por 10 minutos por usuário/empresa. Perguntas de refinamento ("só o mês passado", "agora por vendedor", "filtra cliente Acme") herdam automaticamente módulo, período e filtros do turno anterior.

Isolamento por empresa


Conexões ERP, chaves de IA, módulos, datasets, intenções, sinônimos e diálogos são configurados independentemente por empresa. Um usuário só acessa dados da empresa selecionada.

- i Tagline: *"Seu ERP conversando com você."* O usuário pergunta em português livre; o IA Command cuida de toda a tradução para dados do Protheus.

1.2 Arquitetura em Nuvem — Multi-empresa, Multi-usuário, Multi-canal

O IA Command roda **100% na nuvem**. Uma única instalação atende múltiplos clientes (empresas), cada um com seus próprios números de WhatsApp, usuários autorizados, regras de negócio e forma de acesso ao ERP — tudo isolado, sem que um cliente veja ou influencie os dados de outro.

INFOGRÁFICO 1 — IA COMMAND NA NUVEM, MULTI-TENANT



Multi-empresas (multi-tenant)

Cada cliente é uma empresa isolada por `tenant_id/empresa_id`. Conexões ERP, chaves de IA, módulos, datasets, intenções, sinônimos, diálogos e histórico de conversas são segregados — nenhuma empresa acessa dado de outra.

Multi-usuários

Dentro de cada empresa, o acesso é controlado por número de celular. Só números cadastrados em "Números Autorizados" recebem respostas — permitindo abrir o sistema para diretoria, financeiro ou vendas de forma seletiva.

Multi-canais de WhatsApp

Uma mesma empresa pode operar vários números WhatsApp simultaneamente (ex: canal comercial e canal financeiro), cada um com seu próprio grupo de usuários autorizados e comportamento.

Um canal também pode ser compartilhado por várias empresas do mesmo grupo

O inverso também é possível: um único número WhatsApp pode atender **mais de uma empresa** (útil para grupos econômicos com um canal central). O vínculo canal↔empresa não é 1 para 1 — é uma relação N:N, com cada empresa tendo seus próprios apelidos ("aliases") dentro do canal. Quando a mensagem chega, o sistema primeiro filtra **quais empresas daquele canal têm aquele número de celular autorizado**; se mais de uma empresa possível restar, resolve pela empresa citada na própria pergunta (por nome ou alias), pela empresa marcada como padrão do canal, ou pergunta ao usuário qual empresa ele quer antes de prosseguir.

Nenhuma infraestrutura pesada no cliente


Banco de dados, IA, orquestração, histórico e auditoria vivem na nuvem do IA Command. O cliente não precisa provisionar servidores próprios para o sistema conversacional funcionar.

i O cadastro de empresas, usuários e permissões não é do IA Command — é herdado da plataforma IAHub, que hospeda o IA Command como um de seus sistemas. Login, seleção de empresa ativa e liberação de acesso por usuário acontecem no IAHub antes de qualquer tela do IA Command carregar. Ver [Pré-requisitos de Acesso no IAHub](#).

1.3 Agente Local x Conexão Direta — como a nuvem acessa o ERP do cliente

Para consultar o banco do Protheus na empresa do cliente, o IA Command suporta **duas formas de acesso**, escolhidas por empresa. A própria nuvem decide automaticamente qual usar, com base na configuração salva em **Configurar IA**.

INFOGRÁFICO 2 — DUAS FORMAS DE ACESSO AO ERP DO CLIENTE



Roteamento automático por empresa

A cada consulta, a nuvem verifica `ai_config.agente_local_ativo` para a empresa. Se estiver ativo e URL/token configurados, a query é enviada ao Agente Local; caso contrário, usa a conexão ERP direta cadastrada em "Conexões ERP".

Contrato do Agente Local

A nuvem faz POST `{agente_url}/execute` com corpo `{ sql, limit, uuid, modulo, operacao, empresa_id }` e header `Authorization: Bearer {token}`. O Agente Local responde com `{ rows, status, duracao_ms }`. Timeout de 240s para consultas pesadas. Esse corpo pode viajar criptografado com AES-256-GCM — ver [seção seguinte](#).

Segurança do Agente Local

Aceita apenas **SELECT** — qualquer outro comando é bloqueado antes de tocar o banco. Autenticação por Bearer token, painel administrativo protegido por senha, limite de 50.000 linhas por consulta.

Quando usar cada uma


Use **Agente Local** como padrão: não exige abrir porta de banco para a internet e é mais fácil de auditar. Use **Conexão Direta** quando já existe VPN ou rede segura estabelecida entre a nuvem e o cliente.

⚠ As duas formas **coexistem** no sistema — não é uma substituindo a outra. A escolha é feita por empresa em **Configurar IA → Agente Local**, sem exigir alteração de código.

1.4 Criptografia Ponta a Ponta — AES-256-GCM no Agente Local

Quando o acesso ao ERP usa **Agente Local**, o corpo da requisição/resposta do endpoint `/execute` — o SQL enviado e as linhas de dados retornadas — pode viajar **criptografado de ponta a ponta** com **AES-256-GCM**, além do transporte HTTPS já existente. É uma camada de segurança adicional e opcional, configurável por empresa.

INFOGRÁFICO 4 — ENVELOPE CRIPTOGRAFADO DO ENDPOINT /EXECUTE



COMO O AES-256-GCM FUNCIONA AQUI

Chave simétrica de 256 bits, por empresa

A mesma chave de 32 bytes (256 bits) é usada para cifrar e decifrar — por isso "simétrica". Cada empresa tem sua própria chave (`agente_local_crypto_key`), gerada aleatoriamente (`crypto.randomBytes(32)`) e nunca reaproveitada entre empresas. A chave precisa estar configurada **idêntica** nos dois lados: na nuvem (Configurar IA) e no painel administrativo local do Agente Local. Em nenhum dos dois lados o valor é editado direto em arquivo — cada lado tem seu próprio botão de gerar/colar chave, que grava a configuração automaticamente.

GCM = confidencialidade + integridade no mesmo passo

GCM (Galois/Counter Mode) não é só uma forma de esconder o conteúdo — ele gera uma **tag de autenticação** de 16 bytes junto com o texto cifrado. Se um único byte do envelope for alterado no meio do caminho (adulteração, corrupção de rede), a verificação da tag falha e a descriptografia é rejeitada — o sistema nunca processa um payload que possa ter sido modificado.

IV (vetor de inicialização) único a cada chamada

Cada requisição e cada resposta usa um IV novo, aleatório, de 12 bytes — nunca reutilizado. Isso é uma exigência de segurança do AES-GCM: reusar o mesmo IV com a mesma chave enfraquece a criptografia. O sistema gera um IV novo automaticamente a cada chamada, sem intervenção manual.

Implementação idêntica em Node.js e Python

O envelope é byte-compatível entre os dois lados: `modules/security/aes-gcm-envelope.js` (nuvem, Node.js/crypto nativo) e `agente-local/crypto_envelope.py` (Agente Local, biblioteca `cryptography`) implementam exatamente o mesmo formato — o que um lado cifra, o outro decifra sem ajustes.

O QUE É PROTEGIDO E O QUE NÃO É

Escopo: só o endpoint /execute

A criptografia cobre exclusivamente o corpo da requisição e da resposta do `/execute` — o SQL gerado pela IA e as linhas de dados devolvidas pelo ERP. Outros endpoints do Agente Local (`/apicommand`, sincronização de empresas, configuração) não usam este envelope.

Complementa o HTTPS, não substitui

Se a URL do Agente Local já usa HTTPS, a conexão já é criptografada em trânsito. O AES-256-GCM adiciona uma segunda camada, independente do transporte — útil em redes internas sem HTTPS configurado, VPNs corporativas ou como defesa adicional caso o TLS seja comprometido.

CONFIGURAÇÃO (POR EMPRESA)

Ativar em Configurar IA → Agente Local

Campo "Criptografia AES-256-GCM": gere a chave clicando em **Gerar nova chave** (na nuvem) ou no painel local do Agente Local (**Segurança → Chave de Criptografia → Gerar nova chave**) — qualquer um dos dois lados pode gerar, mas o valor precisa ser colado no outro lado e ativado nos dois. Em nenhum dos dois é preciso editar arquivo manualmente: cada painel grava a própria configuração ao salvar. A chave fica mascarada na tela (***) depois de salva, revelável só sob autenticação.

Modo obrigatório no Agente Local

O `.env` do Agente Local tem a flag `CRYPTO_REQUIRED`. Quando `true`, o agente rejeita (HTTP 426) qualquer chamada a `/execute` que chegue sem criptografia — útil para forçar que nenhuma chamada em claro seja aceita, mesmo por engano de configuração na nuvem.

Falha explícita em caso de descompasso

Se a nuvem está configurada para criptografar mas o Agente Local responde em claro (ou vice-versa), a chamada falha com erro claro em vez de aceitar silenciosamente um formato inesperado — evita que uma configuração incompleta passe despercebida.


! **A chave nunca é enviada pela rede.** Ela precisa ser copiada manualmente da tela "Configurar IA" para o arquivo `.env` do Agente Local durante a instalação. Perder a chave sem backup significa gerar uma nova e reconfigurar os dois lados — não existe recuperação de chave perdida.

1.5 O Fluxo da Mensagem — do WhatsApp até a resposta

Toda pergunta enviada pelo WhatsApp percorre o mesmo ciclo de vida, independentemente do módulo ou da forma de acesso ao ERP escolhida pela empresa.

- 1 O **usuário**, pelo WhatsApp, envia uma pergunta ou comando em linguagem natural (texto ou áudio).
- 2 O **IA Command (nuvem)** recebe a mensagem, identifica a empresa/canal e aplica as regras iniciais — diálogos fixos, normalizações e verificação de número autorizado.
- 3 O sistema envia o contexto da conversa (histórico, período herdado, filtros anteriores) e o prompt para a **Inteligência Artificial** (Groq, OpenAI, Gemini, DeepSeek ou Claude).
- 4 A IA processa a solicitação numa única chamada e devolve um JSON completo: o **contrato semântico** (módulo, período, filtros, agrupamentos) e o **SQL já escrito por ela mesma**, lado a lado na mesma resposta — o sistema não gera o SQL a partir do contrato, é a IA quem escreve o texto SQL literal.
- 5 O **SPEC** (Orquestrador + Guardrails) valida e corrige o SQL contra regras de domínio do Protheus antes de executar.
- 6 O sistema, via API segura, envia o SQL ao **Agente Local** instalado no servidor do cliente (ou, alternativamente, executa via **Conexão Direta**).
- 7 O **Agente Local** executa o SQL no banco de dados do ERP e devolve os dados brutos (JSON) para a nuvem.
- 8 A **nuvem** recebe os dados, formata a resposta em linguagem natural e a devolve ao usuário pelo **WhatsApp**.


DIAGRAMA 0 — CICLO DE VIDA COMPLETO DA MENSAGEM



1.6 Arquitetura IA-first (SPEC) — visão em camadas

A diretriz é **IA-first**: a inteligência artificial externa é o provider principal para qualquer pedido. O conjunto **Orquestrador IA + Guardrails determinísticos** é chamado neste guia de **SPEC** — é ele quem corrige o contrato da IA quando necessário. O motor local resolve apenas como último recurso.

DIAGRAMA 1 — CAMADAS DA ARQUITETURA IA COMMAND




⚠ **IA-first é a diretriz central.** O resolver local nunca deve ser a estratégia principal. Toda nova regra de negócio vai nos guardrails ou sinônimos — nunca no resolver local.

1.7 Motor de Classificação — Cascata de decisão

Para cada mensagem recebida, o sistema percorre uma cascata antes de chegar ao ERP. Entender esse fluxo é essencial para diagnosticar comportamentos inesperados.

DIAGRAMA 2 — CASCATA DE CLASSIFICAÇÃO



Bypass dinâmico (sem chave)

Quando nenhuma empresa do canal tem chave de IA configurada, o sistema não tenta interpretar a mensagem. Ele gera uma intenção vazia (desconhecido, confiança 0) e devolve ao usuário uma mensagem fixa informando instabilidade no serviço de IA — não há processamento alternativo da pergunta.

Guardrails sobrescrevem a IA

Regras determinísticas são aplicadas após o contrato IA. Ex: "contas a pagar" → financeiro/pagar; "saldo bancário" → financeiro; período genérico (mes_atual) é substituído pelo período do contexto anterior.

Fallback de chave global


Se a empresa não tem chave própria, o sistema usa qualquer chave de IA disponível no banco de dados. O sistema funciona mesmo sem configuração específica por empresa.

- i O que o SPEC faz quando a pergunta não se encaixa em nenhuma rotina conhecida:** ele nunca bloqueia o usuário. Se a confiança da classificação ficar abaixo de 0,85, ou se ocorrer um erro estrutural (SQL inválido, período inconsistente, etc.), o sistema não chama nenhum motor alternativo — apenas seleciona, por regra fixa no código (*fallback local*), uma mensagem orientativa pré-escrita correspondente ao tipo de erro, pedindo para o usuário reformular. A IA sempre tem prioridade — o SPEC só interfere para corrigir erros de domínio conhecidos (ex: tabela errada), nunca para impedir uma pergunta nova ou fora do padrão.

1.8 Multi-turn e Contexto Conversacional

O sistema mantém contexto de conversa por usuário/empresa com TTL de 10 minutos. Perguntas de refinamento herdam automaticamente módulo, período, filtros e entidades já resolvidas no turno anterior.

DIAGRAMA 3 — HERANÇA DE CONTEXTO MULTI-TURN



O que é herdado automaticamente

Módulo ERP, período (se não genérico), filtros de entidade já resolvidos (cliente, produto, vendedor, fornecedor), carteira, estado do título, fluxo tipo e nível de contexto.

Comparação mensal/anual vira agrupamento

"Comparação mensal" → agrupar_por: mes; "comparação anual" → agrupar_por: ano. Permite drilldowns temporais sem mudar o filtro de período.

1.9 Stack Tecnológica — o que roda por baixo

O IA Command é construído sobre tecnologias maduras de mercado, sem dependência de infraestrutura proprietária pesada. Cada peça tem um papel único na cadeia — da mensagem no celular do usuário até o dado retornado do Protheus.

Node.js + Express

Runtime e servidor HTTP da aplicação na nuvem. Todo o orquestrador, SPEC, rotas de API e lógica de negócio rodam em JavaScript sobre Node.js, usando Express para expor as rotas REST do sistema.

whatsapp-web.js

Biblioteca que mantém a sessão do WhatsApp Web ativa por canal, permitindo enviar e receber mensagens sem depender da API oficial paga do WhatsApp Business. É o motor por trás do Monitor e da autenticação por QR Code.

better-sqlite3

Banco de dados local (SQLite) usado pela nuvem do IA Command para armazenar configurações, módulos, intenções, sinônimos, diálogos, histórico de execuções e auditoria. Leve, rápido e sem necessidade de servidor de banco dedicado.

Socket.IO

Comunicação em tempo real entre o backend e as telas administrativas — usado para refletir instantaneamente o status de conexão dos canais WhatsApp no Monitor, sem exigir que o usuário atualize a página.

mssql / pg (SQL Server e PostgreSQL)

Drivers de conexão usados na **Conexão Direta** ao ERP do cliente. O Protheus roda tipicamente sobre SQL Server (driver mssql), mas o sistema também suporta PostgreSQL.

Python + FastAPI (Agente Local)

O Agente Local instalado no servidor do cliente é uma API escrita em Python com FastAPI, expondo os endpoints /apicommand (health-check) e /execute. Roda como serviço Windows via NSSM, com driver ODBC (pyodbc) para acessar o SQL Server do Protheus.

Provedores de IA — chamadas HTTP diretas

O sistema não depende de SDKs oficiais de terceiros: ele faz requisições HTTPS nativas do Node.js para a API de cada provedor. **Groq** e **DeepSeek** usam o formato compatível OpenAI (/v1/chat/completions); **OpenAI** usa o mesmo formato na API oficial; **Claude** (Anthropic) usa a API nativa própria (anthropic-version: 2023-06-01, modelo claude-haiku-4-5-20251001); **Gemini** usa a API própria do Google (modelo gemini-3.5-flash).

Transcrição de áudio — Groq/OpenAI Whisper + Gemini multimodal

Mensagens de voz do WhatsApp são transcritas em cadeia de fallback: **Groq Whisper** (whisper-large-v3) → **OpenAI Whisper** (whisper-1) → **Gemini** (gemini-2.5-flash, via prompt multimodal com áudio em base64, já que não há endpoint de transcrição dedicado no Gemini). Ver [Mensagens de Voz](#).

Criptografia AES-256-GCM — crypto nativo (Node.js) e cryptography (Python)

O envelope criptografado do endpoint /execute do Agente Local usa o módulo crypto nativo do Node.js (createCipheriv('aes-256-gcm', ...)) na nuvem e a biblioteca cryptography (pacote Python, classe AESGCM) no Agente Local — nenhuma dependência externa de terceiros além dessas bibliotecas padrão de cada linguagem. Ver [Criptografia Ponta a Ponta](#).

bcryptjs

Hash de senhas para autenticação dos painéis administrativos — tanto na nuvem quanto no painel local do Agente Local.

form-data

Biblioteca Node.js usada para montar requisições `multipart/form-data` ao enviar o arquivo de áudio para transcrição nas APIs da Groq e da OpenAI.

Persistência do cadastro central (IAHub) é em arquivos JSON

Empresas, usuários, permissões e sistemas são armazenados em arquivos JSON no IAHub (não em banco relacional) — diferente do IA Command, que usa SQLite. Cada leitura/escrita processa o arquivo inteiro; o ponto de atenção não é volume de leitura (irrelevante nas quantidades atuais de empresas/usuários), e sim duas escritas simultâneas no mesmo arquivo, que podem sobrescrever uma à outra sem aviso. Não é uma falha ativa hoje — é um ponto conhecido a observar se o uso do IAHub crescer.

- ✓ Nenhuma dessas tecnologias exige licenciamento pago obrigatório: Node.js, Express, SQLite, Socket.IO, Python e as bibliotecas de criptografia nativas são open source. O único custo variável é o consumo das APIs de IA externas (Groq, OpenAI, Gemini, DeepSeek ou Claude), conforme o volume de perguntas processadas.

2


Segurança, Configuração e Operação

Acesso, criptografia, conexão com o ERP, Agente Local e monitoramento do dia a dia

2.1 Pré-requisitos de Acesso no IAHub

Antes de qualquer configuração dentro do IA Command, três coisas precisam existir no **IAHub** — a plataforma que hospeda o IA Command como um de seus sistemas. Sem isso, a tela nem carrega, e o problema não está no IA Command.

INFOGRÁFICO 3 — CADEIA DE ACESSO ATÉ UMA TELA DO IA COMMAND



Empresa cadastrada no IAHub

O cadastro de empresas é feito no IAHub (menu de Empresas), não dentro do IA Command. O `empresa_id` gerado ali é o mesmo usado em todas as tabelas do IA Command (conexões, módulos, execuções).

Sistema "IA Command" habilitado para a empresa

No cadastro de Sistemas do IAHub, a empresa precisa ter o sistema `ia-command` ativado. Sem isso, mesmo um usuário administrador não consegue abrir o IA Command para aquela empresa.

Usuário com o sistema e as rotinas liberadas


Além da empresa, o usuário individual precisa ter o sistema `ia-command` liberado, e cada tela administrativa (Dashboard, Módulos, Números, Mensagens, Intenções, Datasets, Execuções, Auditoria) exige uma rotina própria com prefixo `iac-` (ex: `iac-dashboard`, `iac-execucoes`). Um usuário pode ter acesso ao sistema mas não ver todas as telas.

⚠ Se um usuário relatar "não vejo o menu do IA Command" ou "a tela abre em branco", confira primeiro esses 3 pré-requisitos no IAHub antes de investigar dentro do IA Command — a causa mais comum está aqui, não nas configurações internas.

2.2 Dashboard — Visão geral do sistema

O Dashboard é a tela inicial do IA Command. Exibe o estado geral do sistema: empresas ativas, canais WhatsApp conectados, execuções recentes e indicadores de saúde da IA e das conexões ERP.

dashboard.html — Dashboard IA Command



Objetivo

Visão panorâmica para identificar rapidamente problemas — canal desconectado, empresa sem chave de IA, execuções com erro ou ERP inacessível.

Usabilidade

Use o dashboard diariamente para monitorar o status antes de acionar suporte. Os cartões de status são clicáveis e levam direto à tela de configuração correspondente.

2.3 Segurança — Criptografia em Trânsito e Credenciais em Repouso

Duas perguntas diferentes de segurança costumam ser confundidas: **o que viaja pela rede está protegido?** e **o que fica gravado no banco está protegido?** No IA Command hoje, a resposta é diferente para cada uma — é importante não presumir que "tem criptografia" cobre as duas.

EM TRÂNSITO — REAL E FORTE

AES-256-GCM entre nuvem e Agente Local

O corpo da requisição/resposta do endpoint `/execute` pode viajar criptografado ponta a ponta, além do HTTPS. Ver [1.4 — Criptografia Ponta a Ponta](#) para o funcionamento completo (IV único por chamada, tag de autenticação GCM, chave de 256 bits por empresa).

TLS/HTTPS não valida certificado do Agente Local

As chamadas da nuvem para o Agente Local usam `rejectUnauthorized: false` — ou seja, mesmo quando a URL do agente é HTTPS, a nuvem não verifica se o certificado apresentado é confiável. Isso não anula o HTTPS (o tráfego continua cifrado em trânsito), mas remove a proteção contra um servidor se passando pelo Agente Local com um certificado autoassinado ou inválido. É por isso que a criptografia AES-256-GCM de aplicação (acima) é descrita como uma camada independente do transporte — ela é o que efetivamente protege o conteúdo se o TLS for comprometido, não a verificação de certificado.

EM REPOUSO — MASCARADO NA TELA, NÃO CRIPTOGRAFADO NO BANCO

Senhas de conexão ERP e chaves de API de IA ficam em texto plano no banco

Diferente do que uma leitura rápida da tela pode sugerir, a senha de Conexões ERP e as chaves de API (Groq, OpenAI, Gemini, DeepSeek, Claude) **não são criptografadas antes de gravar no banco SQLite**. O que existe é **maskamento na interface**: depois de salva, a tela mostra *** em vez do valor — isso protege contra alguém olhando a tela por cima do ombro, não contra acesso ao banco de dados.

Rota de "revelar" existe para quem tem a permissão

Usuários com a rotina de configuração de IA liberada podem clicar em revelar e ver a chave em claro novamente — é um recurso legítimo de administração, mas reforça que o dado não está criptografado: se estivesse, não haveria como "revelar" sem a chave de descryptografia correspondente.

O que protege esses dados hoje é controle de acesso, não criptografia


A proteção real das credenciais em repouso é a combinação de login no IAHub + sistema `ia-command` habilitado + rotina específica liberada (ver [2.1 — Pré-requisitos de Acesso no IAHub](#)). Quem não passa por essa cadeia não vê a tela; quem passa, e tem a rotina certa, pode revelar o valor.

! Não presuma "criptografado" quando o correto é "mascarado na tela". Ao orientar um cliente sobre segurança de dados, seja preciso: o tráfego entre nuvem e Agente Local no endpoint `/execute` é criptografado de fato (AES-256-GCM); senhas e chaves salvas no banco de dados, não — elas dependem inteiramente do controle de acesso ao sistema para ficarem protegidas.

2.4 Configurar IA — Provedores e chaves de API

Define qual provedor de IA será usado pela empresa, qual chave de API e qual modelo. Esta é a **primeira configuração a fazer** — sem chave de IA, o sistema opera em modo bypass (apenas casos simples).

`config-ia.html` — Configuração de IA



CAMPOS

Provedor **OBRIGATÓRIO**

Groq (recomendado para latência baixa), OpenAI, Google Gemini, DeepSeek ou Anthropic Claude. A cascata usa a ordem: Groq → OpenAI → Gemini → DeepSeek → Claude.

Chave de API **OBRIGATÓRIO**

Chave gerada na plataforma do provedor escolhido. Armazenada criptografada. Sem ela, apenas o bypass dinâmico funciona para mensagens simples.

Modelo

Opcional. Se não informado, o sistema usa o modelo padrão do provedor. Para Groq, recomenda-se `llama-3.3-70b-versatile`. Para OpenAI, `gpt-4o-mini`.

Temperatura

Controla a criatividade da IA. Para classificação de intenções, use valores baixos (0.1–0.2) para maior consistência. Padrão: 0.1.

COMO CONFIGURAR

- 1 Selecione a empresa no seletor do IAHub antes de abrir a tela.
- 2 Escolha o provedor e informe a chave de API.
- 3 Clique em **Testar conexão** — o sistema envia uma classificação de teste e exibe o resultado.

4 Salve. A chave fica disponível para todas as rotas de IA desta empresa.

- i Se a empresa não tiver chave configurada, o sistema usa automaticamente a chave de qualquer outra empresa no banco de dados (*fallback global*). Configure uma chave própria para garantir isolamento.

2.5 Conexões ERP — Acesso ao Protheus

Configura como o IA Command acessa o banco de dados do Protheus. Cada empresa pode ter múltiplas conexões — uma por ambiente (produção, homologação) ou por filial. A conexão correta é referenciada em cada dataset e intenção.

config-conexoes.html — Lista de conexões

IA Command > Conexões ERP - Administrador J2A TESTE

CONFIGURAÇÃO

Conexões ERP

Configure e teste as conexões com seu banco de dados ERP.

+ Mostrar filtros Sem filtros ou agrupamentos ativos

Conexões cadastradas
1 conexão

NOME	ERP	TIPO	SERVIDOR	FILIAL	ROTA	STATUS	PADRÃO	TESTE	AÇÕES
Protheus_Produção	TOTVS Proth...	api_proxy	http://10.0.19.1...	01	default	Ativa		OK	Testar Syn

FORMULÁRIO DE CONEXÃO (CONFIG-CONEXAO-FORM.HTML)

Nome OBRIGATÓRIO

Identificador interno da conexão. Usado ao associar datasets e intenções. Ex: "Produção TOTVS", "Filial SP".

Tipo OBRIGATÓRIO

Driver de banco: SQL Server (MSSQL), PostgreSQL, Oracle ou MySQL. O Protheus padrão usa SQL Server.

Host / Servidor **OBRIGATÓRIO**

Nome ou IP do servidor de banco de dados. Deve ser acessível pelo servidor onde o IA Command está rodando.

Porta

Padrão SQL Server: 1433. Altere se o servidor usa porta customizada.

Banco de dados **OBRIGATÓRIO**

Nome do banco do Protheus. Geralmente corresponde ao nome da empresa no TOTVS (ex: PROTHEUS12, P12_PROD).

Usuário / Senha

Credenciais de acesso ao banco. Recomenda-se um usuário com permissão somente leitura para segurança. A senha fica **mascarada na tela** (***) depois de salva — ver [2.3 — Segurança: Criptografia e Credenciais](#) para o que isso realmente protege e o que não protege.

O modelo de dados (TRADICIONAL/LOBO_GUARA) não é definido aqui

Diferente do que se poderia supor, esta tela de Conexões ERP não tem campo de modelo de dados. Essa escolha é feita em **Middleware Protheus** — ver [2.7](#) para configurar e [7.2](#) para o conceito completo de como cada modelo resolve isolamento entre empresas/filiais.

⚠ Teste a conexão antes de salvar. Uma conexão com credenciais erradas impede todos os datasets e Text-to-SQL que a referenciam de funcionar.

2.6 Instalando o Agente Local no servidor do cliente

Alternativa recomendada à Conexão Direta (ver [1.3 — Agente Local x Conexão Direta](#)): uma API Python leve instalada no próprio servidor Windows do cliente, que executa o SQL localmente e devolve os dados para a nuvem — sem abrir porta de banco para a internet.

PRÉ-REQUISITOS NO SERVIDOR DO CLIENTE

Python 3.11+

Runtime necessário para rodar a API do Agente Local.

NSSM

Ferramenta que registra o Agente Local como serviço Windows com inicialização automática. Precisa estar no PATH do sistema.

ODBC Driver 17 for SQL Server

Driver de banco usado pelo Agente Local (via pyodbc) para conectar ao SQL Server do Protheus local.

PASSO A PASSO DE INSTALAÇÃO

- 1 Copie a pasta `agente-local/` para o servidor do cliente e crie o ambiente virtual: `python -m venv venv` seguido de `venv\Scripts\pip install -r requirements.txt`.
- 2 Copie `.env.example` para `.env` e preencha as credenciais do banco: `DB_HOST`, `DB_PORT`, `DB_NAME`, `DB_USER`, `DB_PASS`, `FILIAL`.
- 3 Execute `deploy\install-service.bat` como Administrador — cria o serviço Windows `IACommand-Agente` com inicialização automática.
- 4 Acesse o painel administrativo local em `http://localhost:8765` (senha padrão inicial: `admin` — troque no primeiro acesso).
- 5 No painel local, vá em **Segurança** → **Token de API** → **Gerar novo token** e copie o valor gerado. O próprio painel grava o token automaticamente — não é necessário editar nenhum arquivo.
- 6 Na nuvem, acesse **Configurar IA** → **Agente Local**, cole o token e a URL do agente (ex: `http://ip-do-servidor:8765`), ative e salve.
- 7 Clique em **Testar conexão** na tela Configurar IA — confirma que a nuvem consegue chamar o endpoint `/apicommand` (health-check) do agente. Não existe endpoint `/health` nesta API — o nome correto é `/apicommand`.
- 8 Opcional, mas recomendado: ative a [Criptografia AES-256-GCM](#) gerando a chave em um dos dois lados (nuvem ou painel local do agente) e colando no outro — cada painel grava a própria configuração ao salvar.

GERENCIAMENTO E MANUTENÇÃO DO SERVIÇO

Iniciar / parar / remover

Scripts prontos em `deploy\start-service.bat`, `stop-service.bat` e `remove-service.bat`. Também é possível usar NSSM diretamente: `nssm start|stop|restart|status IACommand-Agente`.

Factory Reset

Se os arquivos Python forem alterados manualmente e causarem problemas, o painel local (**Sistema** → **Restaurar Código Original**, confirmando com a palavra `RESTAURAR`) restaura os arquivos originais a partir de `backup_original/` e reinicia o serviço. As configurações do `.env` (token, senha, banco, chave de criptografia) não são afetadas pelo reset.

Sincronização de empresas

Empresas atendidas por aquele agente podem ser sincronizadas da nuvem para o painel local (nome, CNPJ, identidade visual), usado para personalizar o painel administrativo do agente quando ele atende múltiplas empresas.

- ✓ Depois de instalado e testado, ative o Agente Local para a empresa em **Configurar IA** — a partir daí, o [roteamento automático](#) passa a usá-lo em vez da Conexão Direta, sem precisar mexer em datasets ou intenções já cadastrados.

2.7 Middleware Protheus — Segurança e controle SQL

O Middleware Protheus é a camada de segurança aplicada sobre todo SQL gerado pela IA (Text-to-SQL dinâmico). Ele bloqueia operações destrutivas, injeta filtros de tenant e limita o número de linhas retornadas.

config-middleware-protheus.html — Configuração do Middleware

ERP Protheus — Middleware SQL - Administrador

Empresa Teste

IA COMMAND - INTEGRAÇÃO - ERP PROTHEUS

AjudaTestarSalvar configuração

Middleware de Proteção SQL

Define regras de segurança aplicadas ao SQL gerado pela IA antes de executar no Protheus

Modelo de dados do Protheus

Define como as empresas estão organizadas no banco de dados do ERP.

PADRÃO
TRADICIONAL
Cada empresa possui suas próprias tabelas físicas com sufixo (ex.: SF1010, SD1010). Sem necessidade de filtro de empresa no SQL.

MULTI-EMPRESA
LOBO_GUARA
Múltiplas empresas compartilham as mesmas tabelas físicas. O middleware injeta automaticamente o filtro de isolamento por empresa.

Quando o grupo Protheus desta empresa tem **mais de uma empresa jurídica** compartilhando as mesmas tabelas físicas (ex.: grupo 01 = Empresa Cliente C + EMA), importe a hierarquia nas telas **Dicionário SYS_COMPANY** e **Dicionário SYS_COMPANY_CFG** (menu ERP Protheus), depois selecione abaixo qual empresa este cadastro do IAHub representa.

EMPRESA DESTA CONEXÃO (HIERARQUIA IMPORTADA)

— nenhuma hierarquia importada ainda —

⚠ Hierarquia importada mas NÃO validada — o Lobo Guarã não aplica nenhum filtro até validar. [Validar agora](#)

► Modo legado (filtro simples por campo fixo)

Limites de execução

Controla a quantidade máxima de registros retornados e o timeout de cada consulta.

LIMITE DE REGISTROS (SET ROWCOUNT)

30000

Mínimo: 100 - Máximo: 50.000

TIMEOUT DA CONSULTA (MS)

10000

Mínimo: 5.000 ms - Máximo: 300.000 ms

Tabelas bloqueadas

Bloqueio DDL/DML **CRÍTICO**

Impede que qualquer SQL gerado pela IA execute INSERT, UPDATE, DELETE, DROP, CREATE, ALTER ou TRUNCATE. Qualquer tentativa é bloqueada antes de chegar ao banco. Nunca desative.

SET ROWCOUNT

Limita o número de linhas retornadas por consulta (padrão: 500). Evita que queries sem filtro adequado travem o banco ou retornem volumes inviáveis para a resposta WhatsApp.

Modelo de dados — TRADICIONAL ou LOBO_GUARA

É **nesta tela**, seção "Modelo de dados", que se escolhe o modelo — dois cartões clicáveis, **TRADICIONAL** (padrão) ou **LOBO_GUARA**. Ao selecionar LOBO_GUARA, campos extras de vínculo aparecem. O middleware nunca injeta um filtro fixo de filial "cego": em conexões TRADICIONAL não há outra empresa jurídica na mesma base, então não é necessário filtro adicional; em LOBO_GUARA, o isolamento é resolvido pela árvore de vínculo — ver [2.8 — Como Configurar LOBO_GUARA](#) para o passo a passo completo e [7.2](#) para o conceito e o comportamento fail-open.

Validação SX3 (aviso apenas)

Campos usados no SQL gerado pela IA são verificados contra o dicionário SX3. Campos não encontrados geram apenas um aviso nos logs — nunca bloqueiam a execução. Diretriz IA-first: a IA tem prioridade sobre o dicionário.


! Nunca desative o bloqueio DDL/DML. O SQL é gerado por IA e pode conter instruções destrutivas por erro de interpretação ou prompt injection via WhatsApp.

2.8 Como Configurar LOBO_GUARA — passo a passo

Configurar uma conexão como LOBO_GUARA envolve 4 telas em sequência — pular uma etapa deixa a árvore incompleta e o isolamento não funciona. Este passo a passo assume que você já leu [7.2 — LOBO_GUARA vs. Tradicional](#) e entende o conceito.

- 1 Middleware Protheus (config-middleware-protheus.html) → seção "Modelo de dados"** — selecione o cartão **LOBO_GUARA**. Campos extras de vínculo aparecem na tela. No primeiro cadastro, a própria tela avisa que a hierarquia ainda não existe — os próximos passos resolvem isso.
- 2 Dicionário SYS_COMPANY_CFG (admin-protheus-sys-company-cfg.html)** — importe a hierarquia Grupo/Empresa/Unidade/Filial real do Protheus: direto do banco (a tela busca as tabelas SYS_COMPANY*/SYS_COMPANY_CFG* da conexão), ou por arquivo DBF/SDB quando não há acesso direto ao banco (ex.: conexão via Agente Local). Depois de importar, use o botão **Validar** — ele confirma se a árvore importada bate exatamente com os valores reais de filial numa tabela de negócio; só com validação OK o sistema libera resolução automática de escopo.

admin-protheus-sys-company-cfg.html — Dicionário SYS_COMPANY_CFG



- 3 **Vincular cada empresa jurídica Protheus a uma empresa cliente do IAHub** — ainda em SYS_COMPANY_CFG, nas linhas do tipo "empresa" existe a coluna "**Empresa IAHub**" com um seletor. Escolher a empresa ali grava o vínculo (afeta a empresa e todas as suas unidades/filiais de uma vez). **Esse vínculo é a peça central do isolamento** — uma empresa Protheus sem vínculo nunca entra na resolução de escopo, mesmo estando na árvore. Uma segunda empresa Protheus só pode ser vinculada à mesma empresa IAHub se as tabelas físicas realmente forem compartilhadas entre elas (a tela recusa o vínculo com erro se a empresa de destino estiver marcada como TRADICIONAL).
- 4 **Números Autorizados (admin-numeros-whatsapp.html) → aba "Empresas Protheus"** — para cada número, dentro de cada empresa em que ele está autorizado, uma subseção "Filiais Protheus (Chat Web)" mostra a árvore de empresas/filiais para marcar quais aquele número pode acessar. Essa árvore só aparece se a hierarquia já tiver sido importada no passo 2.

⚠ **O controle de filiais em Números Autorizados vale só para o ChatWeb (login por código), não para o WhatsApp comum.** No WhatsApp comum não existe seleção por número: se a empresa tem a árvore validada e a mensagem cita o nome de uma filial, o sistema filtra automaticamente para *qualquer* número autorizado daquela empresa — não só o que teria a filial marcada no ChatWeb. Sem menção de filial na mensagem, nenhum filtro extra é aplicado (fail-open, ver 7.2).

! Ponto de atenção não fechado: a árvore usada em Números Autorizados lista qualquer empresa/filial Protheus cadastrada para aquela empresa IAHub, **sem checar se o vínculo do passo 3 foi confirmado** — diferente do resolver usado no WhatsApp comum, que exige vínculo explícito. Na prática, isso significa que uma empresa Protheus ainda sem vínculo pode aparecer selecionável nessa árvore. Não é um problema documentado como bug, mas é uma assimetria real entre as duas telas — evite deixar empresas sem vínculo na árvore por mais tempo que o necessário.

2.9 Operação — Auditoria, Consumo e Console do Servidor

Além dos logs de execução e interpretação (ver [Fase 9 — Auditoria e Monitoramento](#)), existem telas de operação diária que respondem a perguntas diferentes: quem mexeu em quê, quanto está custando a IA, e o que o processo do servidor está fazendo agora.

TELAS DE OPERAÇÃO

Auditoria administrativa (admin-auditoria.html)

Registro somente leitura de ações administrativas realizadas no sistema — data/hora, usuário, ação e detalhe. Diferente da auditoria de consultas IA (Fase 9), esta tela foca em mudanças de configuração feitas por administradores.

Consumo IA (admin-consumo-ia.html)

Acompanha o uso e custo estimado por provedor de IA (Groq, OpenAI, Gemini, DeepSeek, Claude) ao longo do tempo. Use para identificar picos de consumo, comparar custo entre provedores e antecipar necessidade de ajuste de plano/limites junto ao provedor.

Console do Servidor (console-servidor.html)

Tela de monitoramento do processo backend do IA Command em execução — útil para diagnóstico operacional sem precisar de acesso direto ao servidor.

Cargas do Agente Local (admin-agente-local-cargas.html)


Sincronização de empresas atendidas com o Agente Local instalado no cliente — nome, CNPJ e identidade visual são enviados da nuvem para o painel local, usado quando um único Agente Local atende múltiplas empresas do mesmo grupo.

i Estas telas não substituem a auditoria de consultas IA (Execuções, Interpretações, Log de Módulos — Fase 9): são complementares, voltadas à operação administrativa e de custo, não ao comportamento de uma pergunta específica.

3.1 Monitor — Status dos canais em tempo real

O Monitor é o ponto de controle operacional diário do canal WhatsApp: um terminal de log em tempo real, o painel de QR Code para autenticação, e um painel de diagnóstico da última pergunta processada. Não existem campos de "bateria" ou "mensagens em fila" nesta tela — esses indicadores não fazem parte do monitor real.

monitor.html — Monitor WhatsApp



Autenticação via QR Code

Quando o canal está desconectado, o Monitor exibe o QR Code para escanear com o WhatsApp do número configurado. Após autenticação, o status muda para "Conectado" automaticamente.

Terminal de log em tempo real

Via Socket.IO, o Monitor exibe um fluxo contínuo de eventos do canal — mensagens recebidas, intenção classificada, SQL executado, erros — sem precisar atualizar a página.

Painel "Última Intenção"

Mostra o diagnóstico completo da última pergunta processada no canal selecionado: intenção classificada, IA usada, nível de confiança, SQL gerado (quando Text-to-SQL) e contexto herdado do multi-turn. Útil para acompanhar em tempo real se as respostas estão saindo corretas durante um teste.

Reconexão automática

Se a sessão cair, o sistema tenta reconectar automaticamente. Se a reconexão falhar (ex: número trocou de telefone), o Monitor exibe novo QR Code.

Seletor de canal


Uma empresa pode ter vários canais WhatsApp (ex: canal de vendas, canal financeiro). O seletor no topo da tela troca qual canal está sendo observado no terminal e no painel de última intenção.

⚠ O WhatsApp exige que o número esteja ativo no celular e com Internet. Ao trocar de aparelho ou número, o QR Code deve ser autenticado novamente.

3.2 Canais WhatsApp — Configuração dos números

Cada canal é um número WhatsApp associado a uma empresa. Aqui você cadastra o número, define o nome do canal e vincula à empresa. Após salvar, o canal aparece no Monitor aguardando autenticação via QR Code.

admin-canais-whatsapp.html — Canais WhatsApp



Nome do canal **OBRIGATÓRIO**

Identificador amigável. Aparece no Monitor e nos logs. Ex: "Consultas Comerciais", "Financeiro Diretoria".

Número WhatsApp **OBRIGATÓRIO**


Número completo com DDI e DDD no formato internacional: +5565999990001. Deve ser um número real que receberá as mensagens.

Empresa **OBRIGATÓRIO**

Empresa à qual o canal pertence. Mensagens recebidas neste número são processadas com as configurações e dados da empresa selecionada.

3.3 Números Autorizados — Controle de acesso

Define quais números de WhatsApp podem enviar consultas para cada canal. Quando a lista está vazia, qualquer número é atendido. Com pelo menos um número cadastrado, somente os autorizados recebem respostas.



Número

Número WhatsApp do usuário no formato internacional: +5565999881111.

Nome

Nome para identificação nos logs e auditoria. Não aparece nas mensagens.

Canal

Qual canal WhatsApp este número está autorizado a usar. Um número pode ser autorizado em múltiplos canais.

Ativo

Permite suspender temporariamente o acesso sem remover o cadastro.

- i** Lista vazia = qualquer número atendido. Configure autorizações antes de expor o sistema para evitar consultas indevidas.

3.4 Histórico de Interpretações — onde ver as conversas

O histórico real de conversas do WhatsApp — mensagem recebida, intenção classificada e resposta enviada — não fica em uma tela dentro do menu WhatsApp. Fica em **admin-interpretacoes-v2.html**, dentro do menu **Auditoria e Diagnóstico** (rotina `iac-admin-auditoria`), junto com o restante da auditoria de consultas IA — ver [9.2 — Interpretações](#).

"admin-mensagens-whatsapp.html" não é histórico de conversas

Apesar do nome sugerir histórico, essa tela é um CRUD de **templates de mensagens internas do sistema** — textos fixos como a confirmação de recebimento de áudio (`audio_recebido`) ou o aviso de erro de transcrição (`erro_transcricao`). Não lista conversas de usuários.

Filtros disponíveis no histórico real

Por período, canal, número remetente e intenção classificada. Pesquise por texto da mensagem para identificar padrões de uso.

Expandir uma conversa

Clique em uma linha para ver a mensagem completa recebida e a resposta enviada, incluindo o contrato semântico gerado pela IA, o SQL executado (quando Text-to-SQL) e os dados brutos retornados pelo ERP.

Usabilidade


Use para verificar se as respostas estão corretas, identificar perguntas que geram erros e descobrir termos que precisam ser adicionados como sinônimos.

⚠ Se você está procurando "onde vejo as mensagens dos usuários" e chegou em **admin-mensagens-whatsapp.html**, está no lugar errado — essa tela edita textos fixos do sistema. O histórico de conversas está em **Auditoria e Diagnóstico** → **Histórico de Interpretações**.

3.5 Mensagens de Voz — Transcrição automática por IA

O usuário não precisa digitar — pode enviar um **áudio de voz** pelo WhatsApp com a mesma pergunta livre. O IA Command transcreve automaticamente e processa a transcrição pelo mesmo pipeline de uma mensagem de texto.

DIAGRAMA 5 — CICLO DE VIDA DE UMA MENSAGEM DE VOZ, COM FALLBACK DE TRANSCRIÇÃO



Fallback entre 3 providers, na mesma lógica do texto

A transcrição tenta **Groq** primeiro; se falhar por qualquer motivo (chave ausente, cota esgotada, erro de rede, timeout), cai automaticamente para **OpenAI**; se essa também falhar, tenta **Gemini** por último. É o mesmo critério já usado no fallback de classificação de texto em [Configurar IA](#) — qualquer erro avança para o próximo da fila, não só erro de cota.

Groq e OpenAI transcrevem, Gemini "interpreta"

Groq (Whisper) e OpenAI (Whisper) usam um modelo de reconhecimento de fala dedicado — a transcrição é literal. O Gemini não tem esse tipo de endpoint: o áudio é enviado como anexo dentro de um prompt de texto pedindo a transcrição, processado por um modelo de linguagem generativo. Por isso o Gemini fica por último na ordem — só é usado se os dois primeiros falharem, e pode ocasionalmente resumir ou ajustar o texto em vez de transcrever palavra por palavra.

Cada provider usa sua própria chave

O fallback só funciona nos providers que tiverem chave cadastrada em Configurar IA (`groq_api_key`, `openai_api_key`, `gemini_api_key`). Se só Groq estiver configurado, o comportamento é o mesmo de antes — sem OpenAI/Gemini como chave, esses passos são pulados silenciosamente.

Modelo e idioma configuráveis

Campo `whisper_model` (padrão `whisper-large-v3` na Groq) e `audio_idioma` (padrão `pt`) ficam salvos por empresa em Configurar IA. OpenAI usa o modelo `whisper-1`; Gemini recebe o idioma como instrução de texto no prompt, não como parâmetro estruturado.

Falha de transcrição não trava o sistema

Só quando os três providers configurados falharem (ou nenhum tiver chave), o usuário recebe uma mensagem de erro amigável pelo WhatsApp em vez de ficar sem resposta.

Aviso de processamento

Assim que o áudio chega, o sistema envia uma mensagem confirmando o recebimento antes de transcrever — evita que o usuário ache que a mensagem se perdeu enquanto a transcrição processa.

- i Tipos aceitos: notas de voz gravadas no próprio WhatsApp (ptt) e arquivos de áudio enviados como anexo (audio). O formato de origem é sempre convertido antes do envio ao Whisper.

3.6 Clima e Informações Externas

Além de consultar o ERP, o IA Command responde perguntas que não dependem do Protheus — clima, câmbio, cotação de criptomoedas e cotações agropecuárias. São informações externas, buscadas em tempo real em provedores públicos, sem passar pelo pipeline Text-to-SQL.

Clima — com localização compartilhada ou nome de cidade

O usuário pode compartilhar a localização nativa do WhatsApp (o sistema faz reverse geocoding via Nominatim/OpenStreetMap para identificar cidade/bairro) ou simplesmente digitar o nome da cidade, geocodificado via Open-Meteo. **Não há cidade padrão fixa** — se a pergunta não menciona cidade nem inclui localização, o sistema pergunta ao usuário e guarda uma pendência conversacional, resolvida assim que ele responder.

Câmbio

Cotações via Banco Central (PTAX) e AwesomeAPI.

Criptomoedas

Cotações via CoinGecko.

Cotações agropecuárias

Via AgroDoc/CEPEA.

- i Essas respostas não passam pelo Middleware Protheus nem pelo dicionário SX2/SX3 — são um caminho separado do Text-to-SQL, específico para dados externos ao ERP.

3.7 Grupos e Modelos de Resposta

Duas telas complementares de configuração do canal WhatsApp, além das já vistas nesta fase.

Grupos (admin-grupos-whatsapp.html)

Gestão de grupos do WhatsApp associados a um canal — permite que o IA Command responda perguntas feitas dentro de um grupo, não só em conversas individuais.

Modelos de Resposta (admin-whatsapp-response-config.html)

Personalização do formato das respostas enviadas pelo canal — controla aspectos de como a resposta formatada chega ao usuário, além do conteúdo em si.

4


ChatWeb Protheus

Chat web embutido no ERP e acesso externo com login por WhatsApp

4.1 O que é o ChatWeb — não é o canal WhatsApp real

Apesar do nome da pasta no código (protheus_whatsapp) sugerir integração com o WhatsApp, o ChatWeb **não é uma integração com o WhatsApp real** — é um chat web que clona visualmente a interface do WhatsApp (bolhas verde/branco, modo escuro), hospedado dentro do Protheus e também acessível de fora, falando com o **mesmo backend de IA** usado pelo canal WhatsApp de verdade.

Interface do ChatWeb (esqueleto da UI — captura sem sessão autenticada)



Duas superfícies, um único backend

O ChatWeb roda em duas telas diferentes que compartilham o mesmo backend: **dentro do Protheus** (embutido em uma tela TWebEngine — o navegador Chromium embutido no SmartClient Desktop) e **fora do Protheus** (link público, acessado por qualquer navegador).

Reusa o mesmo pipeline de IA do WhatsApp

O ChatWeb não tem uma lógica de IA própria nem mais simples — importa diretamente os mesmos módulos de domínio usados pelo canal WhatsApp real: classificação de intenção, mesclagem de contexto conversacional, roteamento e execução de SQL (com os mesmos guards de segurança), e formatação de resposta. A única diferença estrutural é que o contexto de conversa anterior vem de um armazenamento próprio (SQLite), já que este canal é stateless por requisição HTTP, em vez de manter estado em memória como o WhatsApp.

Módulo isolado do WhatsApp real

Nenhum arquivo é compartilhado fisicamente com `modules/whatsapp/` — é um módulo próprio (`modules/protheus_whatsapp/`) que importa os mesmos módulos de domínio neutros quanto a canal.

Funcionalidades extras vs. WhatsApp puro

Sidebar de conversas, favoritos de pergunta com SQL fixo/template, encaminhamento de resposta (texto/PDF/Excel/anexo) de volta pelo WhatsApp real para contatos autorizados, seletor de árvore de filiais (em conexões LOBO_GUARA) e múltiplas empresas selecionáveis numa mesma sessão.

⚠ A rotina ADVPL que embute o chat dentro do Protheus (IACCHAT.prw) nunca foi compilada ou testada em um ambiente Protheus real — o repositório do IA Command é Node.js e não tem como validar código ADVPL. O restante do ChatWeb (backend, acesso externo, telas administrativas) está implementado e em uso.

4.2 Acesso de Dentro do Protheus

Quando a rotina ADVPL abre a tela do chat dentro do Protheus, a identidade do usuário Protheus precisa ser transferida para o backend do IA Command antes da primeira mensagem.


- 1 A rotina ADVPL, ao abrir o TWebEngine, chama o backend **servidor-a-servidor** (sem sessão de usuário do IAHub) enviando empresa, celular do usuário (lido do cadastro Protheus) e filial.
- 2 Essa chamada é autenticada por um **segredo compartilhado** configurado por empresa, comparado em tempo constante para evitar vazamento de tempo de resposta como pista de ataque.
- 3 O backend emite um token opaco de sessão (256 bits aleatórios), válido por **8 horas de inatividade** (renovado a cada chamada), guardado com hash — nunca em claro.
- 4 A rotina ADVPL navega o TWebEngine para a URL do chat com esse token. A partir daí, o token vira **Bearer** em todas as chamadas seguintes.
- 5 A identidade do usuário dentro do IA Command é o **número de celular** — o mesmo modelo usado no canal WhatsApp real. O número precisa estar cadastrado em "Números Autorizados" para que os guards de segurança (vendedor, cliente, aprovador) funcionem.

! **O segredo compartilhado precisa estar configurado antes de expor esse acesso em produção.** Se a chave de segredo da empresa não estiver definida, o endpoint de emissão de token servidor-a-servidor fica sem autenticação — qualquer chamada que souber o formato do payload consegue gerar um token válido.

4.3 Acesso Externo e Login por Código OTP

Fora do Protheus, o ChatWeb é acessado por um link público (caminho configurável por empresa). O login não usa senha — usa um **código de 6 dígitos enviado pelo WhatsApp real** da empresa, no mesmo espírito de um 2FA por SMS.

Tela real de login externo do ChatWeb



- 1 O usuário acessa o link público e informa o número de celular.
- 2 O backend verifica se o celular tem permissão sincronizada do Protheus e, se sim, gera um código de 6 dígitos e o envia pelo canal WhatsApp já conectado da empresa (dois envios: aviso + código).
- 3 O código expira em poucos minutos (configurável, padrão 5), é guardado com hash — nunca em claro — e tem limite de tentativas configurável (padrão 5).
- 4 Ao validar o código, o backend emite o mesmo token opaco de sessão da via interna, mais um "ticket de lançamento" de uso único e curta duração — para não expor o token real diretamente na URL do navegador.

CAMADAS ADICIONAIS OPCIONAIS (POR EMPRESA)

Chave de acesso extra na URL

Uma camada a mais de segredo compartilhado no próprio link, além do login por código.

Exigência de HTTPS

Recusa acesso se a conexão não for HTTPS.

Rate limiting por IP e headers de segurança

Limita tentativas por IP e aplica headers como no-store e Referrer-Policy: no-referrer, além de bloquear acesso a câmera/microfone/geolocalização do navegador.

⚠ **A segurança do login depende do canal WhatsApp da empresa estar íntegro** — se o WhatsApp da empresa for comprometido, o login por código também é. Não há hoje uma tela para ver sessões ativas ou revogar um token manualmente: a única forma de encerrar acesso é esperar a expiração natural (8h de inatividade) ou desativar o acesso web da empresa inteira.

4.4 Configuração e Telas Administrativas

Toda a configuração do ChatWeb fica centralizada numa aba dedicada, com duas telas de apoio para auditoria e cadastro.

Configurar IA → aba CHAT (config-ia.html)

Ativar/desativar o acesso web, definir o caminho (path) público, TTL do código OTP (1 a 30 minutos), número máximo de tentativas, exigir HTTPS, chave de acesso extra opcional e o segredo compartilhado usado pela integração ADVPL. O link público é fixo por empresa — não é gerado "por usuário".

Encaminhamentos (admin-protheus-chat-encaminhamentos.html)

Auditoria de quem encaminhou qual resposta do ChatWeb para quem, pelo WhatsApp real.

Usuários Protheus (admin-protheus-web-users.html)

Cadastro de usuários/permisões sincronizados do Protheus (celular, empresas/filiais permitidas) — é a base de quem pode fazer login web.

4.5 Sidebar e Conversas Simultâneas

O ChatWeb não é uma janela de conversa única — é um ambiente de múltiplas conversas persistentes, cada uma podendo ser processada em paralelo, no mesmo espírito de um cliente de mensagens real.

Múltiplas conversas persistentes

Cada conversa é uma sessão própria, gravada no banco (escopada por empresa + celular) — o histórico não some ao fechar o navegador. O usuário cria quantas conversas quiser (botão "Nova conversa"), renomeia e exclui pelo menu de três pontos de cada linha da sidebar.

Processamento realmente concorrente

O usuário pode iniciar uma pergunta numa conversa e trocar para outra (ou abrir uma nova) enquanto a primeira ainda está sendo respondida pela IA — a conversa em processamento mostra um indicador animado de "Consultando o Protheus...", e uma resposta que chega em segundo plano marca a conversa com um indicador de não lida.

Rascunho por conversa

Texto digitado e ainda não enviado é salvo por conversa — trocar de conversa na sidebar não perde o que estava sendo escrito.

Busca de conversas

Campo de busca na sidebar filtra a lista de conversas por texto.

Seleção múltipla de mensagens

Dentro de uma conversa, "Selecionar mensagens" no menu do cabeçalho ativa uma barra com "Selecionar Todas", "Limpar Chat" (apaga todas as mensagens mantendo a conversa) e "Excluir" (mensagens específicas selecionadas).

Esquecer contexto

Reseta a memória de intenção (multi-turn) sem apagar o histórico visual da conversa — disponível como opção no menu do cabeçalho ou digitando "reset"/"limpar contexto" diretamente na mensagem, mesmo comportamento do WhatsApp real.

4.6 Favoritos — Perguntas Salvas com SQL Fixo ou Template

Qualquer resposta da IA pode ser favoritada a partir do menu de contexto da mensagem — o sistema grava o SQL final já auditado daquela resposta específica, para reexecutar depois sem passar pela IA de novo.

Favoritos são por usuário, não compartilhados na empresa

Cada favorito é escopado por empresa e celular — dois usuários da mesma empresa não compartilham a lista de favoritos um do outro, mesmo que perguntem a mesma coisa. Não presuma que favoritar algo torna a pergunta visível para os colegas.

SQL fixo ou SQL template com macros

Um favorito pode gravar o SQL literal (roda sempre igual) ou um template com placeholders de data resolvidos a cada execução (mesmas macros do Agendamento — ver [5.2](#)). Se o SQL salvo tiver macros pendentes de ajuste, o favorito aparece com aviso "Precisa ajustar variáveis" e abre um editor antes de poder ser executado.

Agrupamento por módulo

A lista de favoritos agrupa por módulo Protheus quando há mais de um módulo salvo, com contador e expandir/colapsar por grupo.

Permissão revalidada a cada execução

Um favorito só executa se o celular ainda tiver permissão para aquele módulo no momento da execução — se a permissão foi revogada depois de favoritado, a execução é bloqueada.

"Ver SQL gerado" — ferramenta de auditoria à parte

Item separado do menu de contexto (não exige favoritar): abre um painel com abas SQL / Caminho / Auditoria mostrando o SQL bruto gerado pela IA, o SQL canônico adaptado, o query plan e o trace completo da execução — disponível para qualquer resposta, útil para conferência técnica.

4.7 Encaminhamento para o WhatsApp Real

Uma resposta do ChatWeb pode ser encaminhada de fato para o WhatsApp de um contato autorizado — não é uma cópia de texto, é um envio real pelo canal WhatsApp conectado da empresa.

Três formatos: Texto, PDF ou Excel

Texto usa o mesmo formatador do WhatsApp real. PDF e Excel são gerados no próprio navegador e enviados como anexo. O destino é sempre um contato da lista de [Números Autorizados](#) da empresa — não é uma lista própria do ChatWeb.

Envio passa pelo canal WhatsApp real conectado

O sistema resolve um canal WhatsApp ativo da empresa e despacha a mensagem pelo número de verdade — o contato recebe como uma mensagem WhatsApp comum, não sabe que veio do ChatWeb.

Dois pontos de entrada

"Encaminhar resposta" a partir de uma mensagem específica (menu de contexto), ou "Encaminhar anexo" para enviar um arquivo do próprio computador do usuário (botão no cabeçalho, limite de tamanho por anexo).

"Ver formato WhatsApp" — preview sem enviar

Mostra o texto exato que seria encaminhado, com botão de copiar, sem de fato disparar o envio — útil para conferir antes de decidir.

Auditoria completa

Cada envio é registrado (remetente, destinatário, formato, status de entrega, resumo do conteúdo) na tela de Encaminhamentos (ver [4.4](#)).

4.8 Escopo de Empresa e Filial — Seletor LOBO_GUARA e Multiempresa

Um único botão no cabeçalho ("Empresa e filial") controla dois níveis de escolha ao mesmo tempo: qual(is) empresa(s) cliente do IAHub estão ativas na conversa, e — dentro de conexões LOBO_GUARA — quais empresas jurídicas Protheus e filiais fazem parte do escopo.

Árvore de duas camadas

Nível 0: empresas-cliente do IAHub que o usuário pode acessar (aparece com checkbox só quando há mais de uma disponível). Ao expandir uma empresa: nível 1 = empresas jurídicas Protheus do grupo (LOBO_GUARA), nível 2 = filiais de cada uma. Cada empresa Protheus tem checkbox de três estados (tudo/nada/parcial) — desmarcar uma filial específica rebaixa a empresa para "parcial" com contador X/Y.

A árvore respeita o acesso real do usuário no Protheus

O sistema cruza a árvore cadastrada com as filiais que o próprio Protheus libera para aquele usuário — não aparecem filiais que o usuário não acessaria de dentro do ERP, mesmo que estejam na árvore cadastrada.

Seleção manual na UI tem prioridade sobre o texto da pergunta

Uma vez que o usuário mexe na árvore dentro de uma conversa, essa escolha vence qualquer menção de filial digitada na pergunta, mesmo que o texto cite outra filial. Sem toque na árvore, a resolução por texto livre funciona como no WhatsApp comum. A seleção é lembrada por conversa — trocar de conversa na sidebar pode manter um escopo diferente em cada uma.

Multiempresa: mais de uma empresa cliente na mesma pergunta

Marcar mais de uma empresa no nível 0 muda o pipeline de resposta: a pergunta roda para todas as empresas selecionadas (cada uma podendo ter seu próprio recorte de filial) e o sistema devolve uma única resposta consolidando o resultado das empresas — não é uma resposta tabular, é um texto único combinando os resultados.

Empresa sem configuração LOBO_GUARA

Aparece desabilitada na árvore com o aviso "Esta empresa ainda não está configurada no IA Command" — distinto de "sem filial liberada", para não confundir problema de configuração com problema de permissão de usuário.

4.9 Grid de Dados — Reabrir, Agrupar e Exportar Respostas Tabulares

Qualquer resposta tabular do ChatWeb pode ser reaberta como uma grid completa, no estilo de uma planilha — mesmo depois de dias, sem precisar rodar o SQL de novo.

Grid completa com agrupamento dinâmico

Agrupar por qualquer coluna, busca global em todos os campos, expandir/recolher grupos, escolher quais colunas ficam visíveis, total geral, e "Resetar layout" para voltar ao padrão.

Exportação para Excel e PDF

Botões dedicados exportam a grid (já com o agrupamento/filtro aplicado) para arquivo Excel ou PDF, gerados no próprio navegador.

Layout salvo por resposta

O agrupamento e os filtros escolhidos numa resposta são salvos — reabrir a mesma mensagem depois restaura a mesma configuração de grid.

Reabrir sem reprocessar

Qualquer resposta tabular do histórico de uma conversa pode reabrir a grid completa (com exportação) sem executar o SQL novamente — os dados já retornados ficam disponíveis para reanálise a qualquer momento.

5


Agendamento de Perguntas

Relatórios recorrentes enviados automaticamente pelo WhatsApp

5.1 Como Funciona — Perguntas que rodam sozinhas

Em vez de esperar alguém perguntar "faturamento de hoje" toda manhã, o Agendamento permite cadastrar essa pergunta uma vez e deixar o IA Command enviá-la automaticamente — no horário certo, para os destinatários certos, todos os dias/semanas/meses, sem intervenção humana.

DIAGRAMA 6 — CICLO DE VIDA DE UMA PERGUNTA AGENDADA



Reaproveita o pipeline normal por padrão — não é um atalho

Quando o campo opcional "SQL fixo" não é usado, a pergunta agendada passa exatamente pelo mesmo caminho de uma pergunta digitada: SPEC, IA, geração de SQL, execução no ERP (Agente Local ou Conexão Direta) e formatação da resposta. A única diferença é quem disparou — o scheduler em vez do usuário. Ver [5.2](#) para o caminho alternativo com SQL fixo.

Um destinatário, uma execução

Se um job tem 5 destinatários, o sistema roda o pipeline 5 vezes (uma por número) e envia a resposta individualmente a cada um — não é uma resposta única replicada.

Lock evita execução duplicada

Cada job vencido é "travado" (`lock_until + running_token`) antes de rodar. Se o scheduler tentar processar o mesmo job duas vezes (ex: reinício do processo no meio de um tick), a segunda tentativa é ignorada.


Falha não derruba o agendamento

Se a execução falhar (canal desconectado, erro de SQL, IA indisponível), o job não é desativado — é reagendado automaticamente para `retry_interval_min` minutos depois (padrão: **15 minutos**), mantendo o status "ativo".

5.2 Criar Pergunta Agendada — Campos do formulário e SQL fixo com macros

Tela `admin-agendamento.html` (menu **Agendamento** → **Perguntas Agendadas**, rotina `iac-admin-agendamento`). Cada job define uma pergunta, um canal, uma lista de destinatários e uma regra de repetição.

`admin-agendamento.html` — Nova Pergunta Agendada



CAMPOS

Nome **OBRIGATÓRIO**

Identificador do job, exibido nas telas de histórico e nas mensagens enviadas aos destinatários como prefixo da resposta.

Pergunta **OBRIGATÓRIO**

O texto exato que será processado pelo pipeline, como se um usuário tivesse digitado. Aceita a mesma linguagem livre de uma pergunta manual.

Canal WhatsApp **OBRIGATÓRIO**

De qual canal a mensagem sai. O canal precisa estar conectado (ver Monitor) no momento da execução, ou o job falha e é reagendado.

Destinatários **OBRIGATÓRIO**

Selecionados a partir de "Números Autorizados" da empresa — não é possível enviar para números fora dessa lista. Pelo menos um destinatário é exigido.

Módulo

Opcional. Se fixado (compras/financeiro/faturamento/comissão), só aceita como destinatários números que tenham permissão para aquele módulo específico (flags `modulo_compras`, `modulo_financeiro` etc. em Números Autorizados). Se deixado em "Detectar automaticamente", a IA classifica o módulo a partir da pergunta, como numa mensagem normal.

Ativo / Pausado

Um job pausado não é considerado pelo scheduler, mas continua cadastrado — permite suspender temporariamente sem perder configuração nem histórico.

- Existe também um botão **Executar agora** na tela — dispara o job imediatamente, fora do agendamento, útil para testar a pergunta antes de deixá-la rodando sozinha.

SQL FIXO (OPCIONAL) — PULA A GERAÇÃO DE SQL PELA IA

Um painel opcional no formulário permite substituir a geração de SQL pela IA por um **SQL escrito manualmente**, com suporte a macros. Quando preenchido, o job executa esse SQL fixo diretamente — mais rápido e mais previsível para relatórios que não devem variar de interpretação a cada execução.

EXEMPLO DE SQL FIXO COM MACROS

```
SELECT D2_EMISSAO, SUM(D2_TOTAL) AS TOTAL
FROM SD2020 SD2
WHERE SD2.D2_EMISSAO BETWEEN '{{INICIO_MES}}' AND '{{HOJE}}'
      AND SD2.D_E_L_E_T_ = ' '
      AND SD2.D2_VEND1 = '{{COD_VENDEDOR}}'
GROUP BY D2_EMISSAO
```

GRUPO DE MACRO	EXEMPLOS	O QUE RESOLVE
Data — formato Protheus	{{HOJE}}, {{INICIO_MES}}	Data no formato YYYYMMDD usado nos campos de data do Protheus.
Data — formato ISO	{{HOJE_ISO}}	Data no formato YYYY-MM-DD, para bancos/campos que exigem ISO.
Partes e deslocamentos de data	{{MES_ANTERIOR}}, {{ANO_ATUAL}}	Componentes e deslocamentos relativos à data de execução do job.
Identidade do destinatário	{{CELULAR}}	Número do destinatário da execução atual — permite um único job gerar SQL diferente por pessoa.
Códigos ERP do destinatário	{{COD_VENDEDOR}}, {{COD_CLIENTE_ERP}}	Código Protheus resolvido a partir do celular do destinatário, útil para filtrar automaticamente "só os dados desse vendedor/cliente".

Execução por destinatário quando há macro de identidade

Se o SQL fixo usa uma macro de identidade ou código ERP ({{CELULAR}}, {{COD_VENDEDOR}} etc.), o sistema executa o SQL uma vez por destinatário, substituindo a macro pelo valor de cada um — o mesmo padrão de "um destinatário, uma execução" do pipeline normal.

Fallback automático para IA em caso de falha

Se o SQL fixo falhar na execução, o sistema tenta automaticamente gerar o SQL pela IA como alternativa, em vez de simplesmente reportar erro — evita que um relatório crítico pare de chegar por causa de um SQL fixo desatualizado (ex: campo renomeado no Protheus).

5.3 Tipos de Agenda e Fuso Horário

Cinco tipos de repetição, cada um com sua própria configuração de horário. O cálculo do próximo disparo respeita corretamente o fuso horário escolhido — inclusive troca de mês e dias inexistentes (ex: dia 31 num mês de 30 dias).

TIPO	CONFIGURAÇÃO	COMPORTAMENTO
Manual	—	Nunca dispara sozinho. Só executa via "Executar agora".
Uma vez	Data/hora específica	Executa uma única vez e depois muda para "pausado" automaticamente — não se repete.
Diário	Horário (ex: 08:00)	Executa todo dia no horário definido, no fuso horário do job.
Semanal	Horário + dias da semana	Executa nos dias da semana marcados (ex: seg/qua/sex) no horário definido.
Mensal	Horário + dia do mês	Executa no dia do mês definido. Se o mês não tiver esse dia (ex: dia 31 em fevereiro), usa o último dia disponível do mês.

Fuso horário por job

Cada job tem seu próprio fuso (padrão: `America/Manaus`), escolhido entre os fusos oficiais do Brasil (Brasília, Manaus, Fernando de Noronha, Rio Branco, etc.). Empresas com filiais em fusos diferentes podem ter jobs com horários "locais" corretos para cada uma.

Cálculo correto de fuso horário

O sistema usa `Intl.DateTimeFormat` para converter horário local em UTC considerando o fuso real (não um deslocamento fixo), o que trata corretamente qualquer particularidade de calendário sem intervenção manual.

5.4

Tela `admin-agendamento-historico.html`. Cada disparo de um job gera um registro de execução (*run*) e um registro de entrega por destinatário (*delivery*), permitindo saber exatamente quem recebeu o quê e quando.

IA

A

⚡

🔍

📄

🗨

⚙

🔗

🔌

⚡

🔧

➡

🔧

🕒

☰

IA Command · Historico de Execucoes - Administrador

🏢

Empresa Teste

▼

AGENDAMENTO

Historico de Execucoes

Execucoes dos jobs agendados da empresa ativa.

📄

Limpar log

←

Agendamento

↻

Atualizar

TOTAL

55

SUCESSO

42

PARCIAL

2

ERRO

10

ENTREGAS

6

+ Mostrar agrupamento

Sem agrupamento ativo

☐	ACOES	DATA/HORA	JOB	STATUS	ACIONAMENTO	EXECUCAO VIA	MODULO	ENTREGAS	DUR.
☐	👁	03/08/2026, 18:00:31	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do mês co...	Sucesso	Agendado	SQL Fixo	Faturamento	3/3	
☐	👁	03/08/2026, 18:00:30	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do dia co...	Sucesso	Agendado	SQL Fixo	Faturamento	3/3	
☐	👁	01/08/2026, 18:00:23	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do mês co...	Sucesso	Agendado	SQL Fixo	Faturamento	0/0	
☐	👁	01/08/2026, 18:00:21	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do mês co...	Sucesso	Agendado	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 21:26:01	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do mês co...	Sucesso	Manual	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 21:25:55	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do dia co...	Sucesso	Manual	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 21:06:36	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do mês co...	Sucesso	Manual	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 21:06:26	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do dia co...	Sucesso	Manual	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 20:47:42	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do dia co...	Erro	Manual	SQL Fixo	Faturamento	0/0	
☐	👁	31/07/2026, 20:47:11	Empresa Exemplo - Faturamento e ca Faturamento e carregamento do dia co...	Erro	Manual	SQL Fixo	Faturamento	0/0	

Status da execução (run)

Sucesso: todos os destinatários receberam. **Parcial:** pelo menos um destinatário falhou, mas outros receberam. **Erro:** nenhum destinatário recebeu.

Gatilho (trigger tipo)

`schedule` — disparado pelo scheduler no horário programado. `manual` — disparado pelo botão "Executar agora".

Rastreabilidade até o SQL

Cada execução linka ao mesmo log de interpretação (`interpretation_log`) usado nas mensagens manuais — dá para ver o SQL gerado, o resultado e o tempo de resposta de uma pergunta agendada exatamente como se investiga uma pergunta comum.

Entregas por destinatário

Expandir uma execução mostra a lista de destinatários com status individual (sucesso/erro) e horário de envio — útil quando um número específico não está recebendo, mas os demais sim.

Limpeza de histórico

É possível excluir execuções selecionadas ou limpar por período/job. O cadastro do job em si nunca é removido por essa limpeza — só o histórico de execuções.

⚠ Um job pausado ou com canal desconectado no horário programado **não gera execução silenciosa** — ele tenta, falha, e a falha fica registrada com retry automático. Se um relatório esperado não chegou, confira aqui antes de qualquer outra investigação.

6

Conhecimento ERP


Módulos → Datasets → Intenções → Sinônimos → Diálogos → Normalizações

i Esta fase agrupa as telas **por assunto**, para facilitar o aprendizado — mas no menu real do sistema elas não ficam num bloco único. **Módulos, Intenções, Sinônimos e Normalizações** ficam no menu "Conhecimento da IA"; **Datasets** fica no menu "Configuração" (junto de Conexões ERP); **Diálogos** fica no menu "Administração". Se procurar um item pelo nome deste guia e não achar no mesmo lugar dos outros, é por isso.

6.1 Módulos — Domínios de negócio

Módulos organizam o conhecimento ERP em domínios de negócio: Faturamento, Financeiro, Compras, Comissão, Estoque. Cada módulo agrupa datasets e intenções relacionados.

admin-modulos.html — Módulos



FORMULÁRIO DE MÓDULO (ADMIN-MODULO-FORM.HTML)

Nome **OBRIGATÓRIO**

Nome do domínio. Ex: "RH", "Fiscal". Os 4 módulos dinâmicos padrão (compras, faturamento, financeiro, comissão) são criados automaticamente e não precisam ser cadastrados.

Descrição

Texto explicativo usado pela IA para entender o escopo do módulo durante a classificação.

Conexão ERP padrão

Conexão de banco de dados usada pelos datasets deste módulo. Pode ser sobrescrita no nível do dataset individual.

Palavras-chave

Termos que ajudam a IA a identificar que uma pergunta pertence a este módulo. Complementa os sinônimos do sistema.


- i** Os módulos **compras_dinamico**, **faturamento_dinamico**, **financeiro_dinamico** e **comissao_dinamico** são criados automaticamente na inicialização (semeados na lista padrão de intenções dinâmicas). Não é necessário cadastrá-los manualmente.

⚠ **Estoque (*) é um caso diferente dos outros 4.** O módulo tem um spec completo no código (dicionário de dados, classificador, handler de SQL — ver [7.11 — Dicionário de Dados: Estoque](#)), mas **não é semeado automaticamente** na lista de intenções dinâmicas padrão como os outros 4. Perguntas de estoque que a intenção dedicada não capturar caem no spec genérico, que atua como rede de segurança. Na prática funciona, mas não é plenamente equiparado aos 4 módulos "de primeira classe" — se uma pergunta de estoque se comportar de forma inconsistente, essa é a causa mais provável.

6.2 Datasets — SQL base por intenção

Um dataset é um SQL fixo parametrizado que o sistema executa quando a intenção correspondente é identificada. Diferente do Text-to-SQL dinâmico, o SQL do dataset é escrito manualmente pelo administrador e não muda. Use para consultas simples, estáveis e de alto volume.

admin-datasets.html → admin-dataset-form.html



Nome **OBRIGATÓRIO**

Identificador interno. Usado para vincular o dataset a intenções específicas.

SQL Base **OBRIGATÓRIO**

Query parametrizada com placeholders :PARAM_NOME. Os parâmetros mais usados são :DATA_INI, :DATA_FIM, :EMPRESA, :FILIAL, :CLIENTE, :PRODUTO. O sistema substitui os parâmetros com os valores extraídos da intenção.

Conexão ERP

Qual conexão de banco executar. Se não informado, herda a conexão do módulo pai.

Modo de resposta

Como formatar o resultado: **tabela** (lista com colunas), **total** (soma de um campo), **ranking** (top N), **comparativo** (período atual vs anterior). Informa o formatador de resposta.

Limite de linhas


Máximo de linhas a retornar. Para respostas WhatsApp, mantenha abaixo de 20. Para relatórios, pode ser maior (o middleware ainda aplica o ROWCOUNT global).

⚠ Inclua sempre `D_E_L_E_T_ = ' '` nos filtros WHERE para excluir registros deletados logicamente do Protheus.

6.3 Intenções — Mapeamento de pedidos do usuário

Uma intenção é a estrutura que mapeia um tipo de pedido do usuário a uma ação do sistema. Quando a IA identifica que o usuário quer "faturamento por cliente", ela aponta para a intenção correspondente, que define qual dataset ou pipeline executar.

`admin-intencoes.html` → `admin-intencao-form.html`



Nome **OBRIGATÓRIO**

Identificador único da intenção. Por convenção: `modulo_indicador_dimensão`. Ex: `fat_mensal_produto`, `fin_contas_pagar`.

Módulo **OBRIGATÓRIO**

Módulo ao qual a intenção pertence. Usado para rotear a consulta corretamente.

Termos ativadores

Palavras e frases que, quando detectadas, apontam para esta intenção. Complementam os sinônimos globais. Ex: "faturamento mensal", "vendas do mês", "NF emitida".

Dataset vinculado

Para intenções do tipo dataset: qual SQL base executar. Para intenções dinâmicas, este campo não é usado — o Text-to-SQL gera o SQL em tempo real.

Prioridade

Quando múltiplas intenções são candidatas, a de maior prioridade é escolhida. Intenções dinâmicas têm prioridade alta por padrão.

- As intenções ***_dinamico** (compras, faturamento, financeiro, comissão) são criadas automaticamente e não precisam de dataset — elas usam o pipeline Text-to-SQL que gera o SQL na hora.

6.4 Sinônimos / Equivalências — Vocabulário da empresa

Sinônimos ensinam ao sistema os termos específicos da empresa: apelidos de módulos, abreviações, nomes locais de clientes e produtos. O sistema já possui **123 sinônimos embutidos** para termos comuns — configure aqui apenas o vocabulário exclusivo da empresa.

admin-sinonimos.html — Sinônimos / Equivalências

admin-sinonimos.html — Sinônimos / Equivalências

IA Command · Equivalências - Administrador

J2A TESTE ▾

CADASTROS

Dicionário de Equivalências

Ensine a IA os termos e jargões específicos da sua empresa.

+ Mostrar filtrosSem filtros ou agrupamentos ativos

Equivalências da empresa

123 equivalências

TERMO	CAMADA	EQUIVALÊNCIA	CONTEXTO	STATUS	ORIGEM	CRIADO EM	AÇÕES
custo produto	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo mercadoria	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
cmv	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo unitario	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo unitário	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo medio	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo médio	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
cme	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
cto	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...
custo	Coluna	custo		Ativo	Sistema	2026-09-14 15:46	✎ ...

Termo da empresa **OBRIGATÓRIO**

A palavra ou frase como o usuário a usa. Ex: "fat", "movimento", "pgto", "NF saída". Pode conter espaços e acentos.

Equivale a **OBRIGATÓRIO**

O termo canônico que o sistema entende. Ex: "faturamento", "vendedor", "contas a pagar".

Camada

Classifica o sinônimo em uma de três camadas: **Intenção** (apelido de módulo/domínio — ex: "fat"→faturamento), **Filtro** (apelido de dimensão usada em WHERE — ex: "representante"→vendedor), **Coluna** (apelido de campo do Protheus usado em SELECT/agrupamento). Não é mais um "tipo" livre (módulo/entidade/operação/período) — é sempre uma dessas três camadas.


i Motor local soma sinais das três camadas para calcular confiança. Quando um sinônimo de Intenção + um de Coluna + um de Filtro combinam com período/agrupamento/limite/métricas do dataset, o sistema pode montar a resposta sem chamar a IA — só quando a confiança combinada fica alta o suficiente. Isso não está limitado a "mapear termo para intenção/módulo": é um mecanismo de pontuação, não uma tabela de tradução simples.

✓ Sinônimos são a forma mais eficiente de melhorar a taxa de acerto sem alterar código. Quando um usuário usa um termo não reconhecido, adicione-o aqui antes de ajustar qualquer outra configuração.

6.5 Diálogos — Respostas conversacionais

Diálogos são respostas fixas para mensagens que não são consultas ao ERP — saudações, perguntas sobre o sistema, comandos de ajuda. Evitam que mensagens como "oi", "bom dia" ou "o que você faz?" gerem erros de classificação.

admin-dialogos.html — Diálogos



Gatilho **OBRIGATÓRIO**

Palavras ou frases que ativam este diálogo. Múltiplos gatilhos separados por vírgula. O sistema verifica se a mensagem contém algum dos gatilhos (busca parcial).

Resposta **OBRIGATÓRIO**


Texto que será enviado ao usuário quando o gatilho for detectado. Suporta quebra de linha e emojis.

Prioridade

Diálogos com maior prioridade são verificados primeiro. Se um diálogo combinar, a classificação IA não é chamada para esta mensagem, economizando tokens.

6.6 Normalizações — Padronização de entradas

Normalizações definem transformações aplicadas ao texto da mensagem antes da classificação. Permitem corrigir abreviações, remover palavras desnecessárias, padronizar grafias e expandir acrônimos — tornando a mensagem mais clara para a IA interpretar.



Padrão **OBRIGATÓRIO**

Texto literal ou expressão regex a ser substituído. Ex: `fat\b` para substituir "fat" inteiro sem afetar "fatia" ou "fatura".

Substitui por **OBRIGATÓRIO**

Texto de substituição. Normalizações são aplicadas em cascata na ordem configurada antes de qualquer classificação.

Tipo

Classifica a normalização em cinco tipos: **Geral** (transformação genérica de texto), **Correção** (erro de digitação/grafia), **Abreviação** (expansão de sigla/abreviatura), **Verbo** (padronização de ação), **Métrica** (padronização de indicador numérico). Não são mais os quatro tipos período/módulo/entidade/geral.

Ordem

Normalizações são aplicadas da menor para maior ordem. Configure a ordem para evitar conflitos quando uma normalização pode afetar o resultado de outra.

- i** Diferença entre sinônimos e normalizações: sinônimos mapeiam termos para intenções/módulos. Normalizações transformam o texto bruto antes da classificação — são aplicadas primeiro, ao texto da mensagem inteiro.

Text-to-SQL Dinâmico

A IA gera SQL em tempo real com base no esquema real do Protheus

7.1 Pipeline Text-to-SQL — 8 passos

Quando uma intenção dinâmica é identificada (compras, faturamento, financeiro ou comissão), o sistema executa um pipeline de 8 passos para gerar, validar e executar o SQL no Protheus. Cada passo é logado para diagnóstico.

DIAGRAMA 4 — PIPELINE TEXT-TO-SQL DINÂMICO (8 PASSOS)



Passo 1 — Contrato Temporal

Combina resolução determinística de período (DATA_INI, DATA_FIM) com sugestão da IA. Confiança mínima para aceitar sugestão IA: 0,80.

Passo 2 — Query Plan (determinístico, sem IA)

O sistema interpreta o texto da pergunta por regras fixas (regex/normalização) — não é a IA quem faz esse passo. Resultado: um plano técnico estruturado (tabelas/regras prováveis, ex. "exigir saldo em aberto") usado como contexto para o prompt e como validação do SQL depois de gerado — não é um resultado enviado à IA para "virar SQL".

Passo 3 — Resolução de entidades

Busca no Protheus o código real da entidade mencionada. "Acme" → busca em SA1 pelo nome, retorna código. Tolerância a erros de digitação: termos curtos usam busca por prefixo (5 chars).

Passo 4 — Geração de SQL pela IA

Numa única chamada, a IA recebe o prompt com o query plan, entidades resolvidas, esquema SX2/SX3 e regras do módulo — e devolve um JSON completo contendo o contrato semântico e o texto SQL já escrito por ela mesma, lado a lado. O sistema não monta o SQL a partir de campos estruturados; ele normaliza e valida o SQL que a IA escreveu (ver Passos 5-6).

Passo 5 — Validação SX3 (aviso)

Verifica se os campos do SQL existem no dicionário SX3. Campos não encontrados geram log "Aviso SX3 ignorado por diretriz IA-first" — a execução continua normalmente.

Passo 6 — Middleware SQL

Bloqueia DDL/DML, aplica SET ROWCOUNT e resolve o escopo de isolamento entre empresas/filiais — em conexões TRADICIONAL não há filtro adicional a injetar; em conexões LOBO_GUARA, aplica os guards descritos em 7.2. Se bloqueado, retorna erro sem executar nada no banco.

Passo 7 — Execução ERP

SQL final executado na conexão Protheus configurada. Resultado retornado como array de objetos.


Passo 8 — Formatação IA

Para resultados simples (<50 linhas, sem group_by composto), a IA formata a resposta em linguagem natural. Para grandes volumes, o formatador local é usado.

7.2 LOBO_GUARA vs. Tradicional — os dois modelos de dados Protheus

Toda empresa cadastrada no IA Command aponta para uma conexão Protheus real, que segue um de dois modelos de particionamento de dados. A IA gera SQL "cego" a essa distinção — sempre via SX2/SX3 canônico; é o **backend** que resolve isolamento entre empresas/filiais. Confundir os dois modelos leva a diagnósticos errados de duplicação ou vazamento de dados.

DIAGRAMA 7 — TRADICIONAL VS. LOBO_GUARA: COMO CADA MODELO RESOLVE ISOLAMENTO



HIERARQUIA REAL DO PROTHEUS (VALE PARA OS DOIS MODELOS)

Grupo → Empresa → Unidade → Filial. O sufixo numérico da tabela física (ex: SC7010) representa o **Grupo** — cada grupo tem sua própria família de tabelas físicas, resolvida pelo SX2 (mecanismo maduro, nunca alterado por

este recurso). Dentro de um grupo, o campo de filial das tabelas de negócio (C7_FILIAL, CR_FILIAL) é a concatenação Empresa+Unidade+Filial — comparação direta, sem SUBSTRING.

MODELO TRADICIONAL (PADRÃO)

1 conexão = 1 grupo Protheus = 1 única empresa jurídica

Todas as filiais do grupo pertencem ao mesmo CNPJ/cliente. "Sem filtro de filial" está correto por padrão — não há outra empresa jurídica para vazar dado. É o modelo de todas as conexões, salvo configuração explícita em contrário.

MODELO LOBO_GUARA

Múltiplas empresas jurídicas dentro de um único grupo Protheus

Mesma tabela física pode conter registros de CNPJs diferentes misturados — ex: um grupo com duas empresas distintas usando as mesmas tabelas SC7010/SCR010. Isso exige um mecanismo de resolução que o modelo TRADICIONAL não precisa.

Peça central de isolamento: vínculo explícito à árvore de empresas

Cada empresa jurídica Protheus dentro do grupo só entra na resolução de escopo se estiver **explicitamente vinculada** a uma empresa cliente do IA Command. Uma empresa Protheus sem vínculo fica automaticamente fora de qualquer resolução — não por um filtro que a bloqueia, mas porque nunca é candidata elegível. Essa é a proteção real hoje, não um filtro de SQL ativo.

Comportamento fail-open quando a pergunta não menciona filial/empresa


Se uma pergunta não cita nome de filial/empresa e não há contexto herdado do multi-turn, **nenhum filtro de escopo é injetado no SQL** — o sistema nunca bloqueia a resposta por falta de menção explícita. Isso é seguro apenas enquanto todas as empresas jurídicas do grupo com dado relevante estiverem vinculadas à mesma empresa cliente. Se uma segunda empresa jurídica do mesmo grupo virar cliente do IA Command, perguntas sem menção explícita de empresa/filial passam a poder misturar dados das duas.

! Antes de suspeitar de vazamento ou duplicação numa conexão LOBO_GUARA, verifique nesta ordem:
(1) o modo de compartilhamento entre filiais e entre empresas da(s) tabela(s) envolvida(s) — são dois eixos independentes, uma tabela pode ser compartilhada entre filiais mas exclusiva por empresa; (2) quantas empresas jurídicas têm vínculo explícito configurado para aquela conexão; (3) só então avaliar se é um JOIN/filtro incompleto ou ausência real de dado no período testado.

7.3 Guards de Identidade — arquitetura compartilhada entre 4 módulos

Além do isolamento entre empresas (LOBO_GUARA), existe uma segunda camada de segurança: garantir que um usuário só veja os próprios dados dentro da mesma empresa — um vendedor não vê a comissão de outro, um cliente não vê pedido de outro cliente. Isso é resolvido por um conjunto de **guards de identidade**, reutilizados em 4 módulos diferentes, não uma regra isolada de Comissão.

DIAGRAMA 9 — GUARDS DE IDENTIDADE, ARQUITETURA COMPARTILHADA



Guard de vendedor/gestor

Resolve a identidade de vendedor ou gestor a partir do número de WhatsApp que enviou a pergunta. Usado em Comissão, Faturamento e Financeiro. Gestor vê tudo; vendedor só vê o que está filtrado pelo próprio código, nunca pelo nome.

Guard de cliente

Resolve a identidade de cliente a partir do WhatsApp, quando o número pertence a um cliente externo com acesso ao sistema — usado em Faturamento e Financeiro.

Guard de aprovador

Resolve a identidade de aprovador de compras a partir do WhatsApp — usado no módulo Compras, para limitar visualização a pedidos sob a alçada daquele aprovador.

Guard de mapeamento de entidade

Mapeia campos de código equivalentes por tipo de entidade (cliente, fornecedor, vendedor) entre os diferentes módulos, já que o mesmo conceito de negócio pode usar campos com nomes diferentes em cada tabela Protheus.

- ⚠ Todo número de WhatsApp é resolvido em "Números Autorizados" antes de qualquer SQL ser gerado. Número não cadastrado bloqueia a execução — o sistema nunca revela nome ou código de outra identidade por engano de classificação da IA.

7.4 Dicionário SX2 — Tabelas do Protheus

O SX2 é o dicionário de tabelas do Protheus. O IA Command consulta o SX2 para descobrir quais tabelas físicas existem no banco — especialmente útil para tabelas com sufixo de empresa (ex: SA1010, SF2020). Essas

informações são usadas para enriquecer o prompt de geração de SQL.

admin-protheus-sx2.html — Dicionário SX2 — Tabelas

IA

ERP PROTHEUS

A

Dicionário SX2

Modos de compartilhamento das tabelas Protheus — usados pela IA para aplicar o filtro de filial correto.

Ajuda

Importar

Nova Tabela

Todas as conexões

Mostrar filtros

Sem filtros ativos

Tabelas cadastradas

10782 tabelas

CONEXÃO	CHAVE	ARQUIVO (X2_ARQUIVO)	MODO FILIAL	MODO UNI...	MODO EMP...	DESCRIÇÃO	AÇÕES
Protheus_Produção	A00	A00010	C	—	—	Território x Nível do Agrup.	
Protheus_Produção	A01	A01010	C	—	—	Exceção Territoriais x Agrup.	
Protheus_Produção	A02	A02010	C	—	—	Exceção por Níveis do Ag...	
Protheus_Produção	A03	A03010	C	—	—	Sequenciador	
Protheus_Produção	A04	A04010	C	—	—	Sequencia x Agrupador	
Protheus_Produção	A05	A05010	C	—	—	Script x Rotina	
Protheus_Produção	A06	A06010	C	—	—	Item Script Validado	
Protheus_Produção	A08	A08010	C	—	—	Agrup. x Regras para Pesquis...	
Protheus_Produção	A09	A09010	C	—	—	Membros x Território	
Protheus_Produção	A0A	A0A010	C	—	—	EQUIPE X USUARIOS	

Objetivo

Permite verificar quais tabelas estão disponíveis no Protheus conectado. Use para diagnosticar problemas no Text-to-SQL quando a IA gera referências a tabelas inexistentes.

Modos de tabela

E (Exclusivo): tabela com sufixo de empresa (SA1010). C (Compartilhado): tabela sem sufixo. G (Global): tabela global sem filial.

Usabilidade

Use como referência ao configurar datasets manuais ou ao diagnosticar erros de "tabela não encontrada" no log de consultas. O sistema usa essas informações automaticamente — esta tela é somente leitura.

7.5 Dicionário SX3 — Campos do Protheus

O SX3 é o dicionário de campos do Protheus. O IA Command consulta o SX3 para enriquecer o prompt de geração de SQL com os campos reais de cada tabela — nome, tipo, tamanho e descrição. Isso aumenta significativamente a

precisão do SQL gerado pela IA.

admin-protheus-sx3.html — Dicionário SX3 — Campos

IA

⌂

☰

IA Command / Protheus > Dicionário SX3 - Administrador

J2A TESTE

A

ERP PROTHEUS

Dicionário SX3

Campos das tabelas Protheus usados pela IA para validar nomes, tipos e disponibilidade antes de gerar SQL.

AjudaImportarNovo Campo

Todas as conexões

+ Mostrar filtros

Sem filtros ativos

Campos cadastrados

179232 campos

CONEXÃO	TABELA	CAMPO	TIPO	TAM.	DEC.	TÍTULO	DESCRIÇÃO	AÇÕES
Protheus_Produção	A00	A00_FILIAL	C	2	0	Filial	Filial do Sistema	 
Protheus_Produção	A00	A00_CODTER	C	6	0	Cod. Territ.	Código do Território	 
Protheus_Produção	A00	A00_CODAGR	C	6	0	Cod. Agrup.	Código do Agrupador	 
Protheus_Produção	A00	A00_NIVAGR	C	3	0	Nível	Nível Agrupador	 
Protheus_Produção	A00	A00_DSCNIV	C	40	0	Descrição	Descrição do Nível	 
Protheus_Produção	A00	A00_DTINIC	D	8	0	Data Inicial	Data Inicial	 
Protheus_Produção	A00	A00_DTFIM	D	8	0	Data Fim	Data Final	 
Protheus_Produção	A00	A00_OPER	C	1	0	Operação	Operação	 
Protheus_Produção	A00	A00_PONTOS	N	4	0	Pontos	Pontos	 
Protheus_Produção	A00	A00_MSBLQL	C	1	0	Status ?	Status ?	 

Objetivo

Referência para validar campos usados nos SQLs gerados pela IA e nos datasets manuais. Permite identificar o nome exato e tipo de cada campo do Protheus.

Busca por tabela

Informe o prefixo da tabela (ex: "SD2", "SE1", "SA1") para ver todos os campos disponíveis. Os campos são carregados diretamente do banco Protheus configurado.

Usabilidade

Use quando precisar escrever um SQL base num dataset manual ou quando o Text-to-SQL estiver gerando campos errados. Esta tela é somente leitura — os dados vêm do Protheus em tempo real.

i A validação SX3 no pipeline Text-to-SQL gera apenas avisos nos logs — nunca bloqueia a consulta. Campos gerados pela IA que não constam no SX3 ainda podem ser válidos se a empresa customizou o Protheus.

7.6 Log de Consultas SQL — Histórico completo de queries

Registra todas as queries SQL geradas pelo Text-to-SQL dinâmico — texto da pergunta original, SQL gerado, tempo de execução, número de linhas retornadas e status. Essencial para auditar e otimizar a qualidade das consultas geradas pela IA.

admin-logs-consultas.html — Log de Consultas SQL

Log de Consultas IA

IA COMMAND · ERP PROTHEUS

Log de Consultas · 15 registro(s)

Limpar logAtualizar

+ Mostrar agrupamentoSem agrupamento ativo

DATA/HORA	MÓDULO	PERGUNTA	SQL GERADO	STATUS	ROWS	PROVIDER	PROC.	PIPELINE	ENTRE...
21/08/2026, 08:53	Faturamento	Faturamento do mes com nome...	SET ROWCOUNT 10000; ...	✓ Sucesso	0	openai	24.1s	—	—
20/08/2026, 10:19	Faturamento	Faturamento do mes com nome...	SET ROWCOUNT 10000; ...	✓ Sucesso	0	openai	21.4s	—	—
20/08/2026, 10:11	Faturamento	Faturamento do mes com nome...	SET ROWCOUNT 10000; ...	✓ Sucesso	0	openai	48.8s	—	—
20/08/2026, 09:06	Faturamento	Faturamento do mes com nome...	SET ROWCOUNT 50000; ...	✗ Erro	—	openai	47.7s	—	—
18/08/2026, 07:18	—	bom dia lista chamados em atra...	—	🗨️ Diálogo	—	openai	2.3s	—	—
17/08/2026, 10:51	Faturamento	Qual o faturamento do mês 08	-- 32A TESTE SET ROW...	✓ Sucesso	2	openai	13.2s	13.2s	13.3s
17/08/2026, 10:51	Faturamento	Qual o faturamento do mês 08	SET ROWCOUNT 10000; ...	✓ Sucesso	0	openai	7.5s	—	—
14/08/2026, 17:10	—	RESET	—	desconhecido	—	groq	679ms	—	—
14/08/2026, 17:06	Financeiro	Contas a pagar da semana	SET ROWCOUNT 10000; ...	✓ Sucesso	15	groq	13.3s	—	—
14/08/2026, 17:03	Faturamento	aturamento do ano do mes de j...	SET ROWCOUNT 10000; ...	✓ Sucesso	2.514	groq	157.5s	—	—
14/08/2026, 16:59	Faturamento	Faturamento do ano do mes de ...	SET ROWCOUNT 10000; ...	✓ Sucesso	2.514	groq	25.3s	—	—
14/08/2026, 16:56	Faturamento	Faturamento do ano do mes de ...	SET ROWCOUNT 50000; ...	✗ Erro	—	groq	29.8s	—	—
14/08/2026, 16:54	Faturamento	Pedi com DATA DE EMISSÃO e n...	SET ROWCOUNT 10000; ...	✓ Sucesso	9.221	groq	29.6s	—	—
14/08/2026, 16:53	Faturamento	Faturamento do ano por mes or...	SET ROWCOUNT 10000; ...	✓ Sucesso	9.221	groq	44.2s	—	—
14/08/2026, 09:22	—	Não pedi periodo, quero todos	—	🗨️ Diálogo	—	groq	397ms	—	—

SQL gerado (expandir)

Clique em qualquer linha para ver o SQL completo gerado pela IA, os parâmetros substituídos e o resultado bruto retornado pelo ERP.

Avisos SX3

Consultas com status "Aviso SX3" tiveram campos não encontrados no dicionário mas executaram normalmente. Verifique se o resultado está correto antes de agir.

Usabilidade

Use para identificar padrões de consulta frequentes (candidatos a virar datasets fixos), consultas lentas (otimização de índices) e consultas que retornam 0 linhas (possível erro de filtro).

7.7 Dicionário de Dados — Compras

Tabelas, campos e joins que o spec do módulo Compras conhece e usa para gerar SQL. Cobre notas de entrada, pedidos de compra e devoluções ao fornecedor.

TABELA	O QUE É	CAMPOS PRINCIPAIS
SF1	Cabeçalho de NF de entrada. F1_VALBRUT = valor bruto total da nota.	F1_FILIAL, F1_DOC, F1_SERIE, F1_FORNECE, F1_LOJA, F1_EMISSAO, F1_DTDIGIT, F1_TIPO, F1_VALBRUT, F1_VALMERC, F1_TOTALNF
SD1	Itens de NF de entrada. Métrica: D1_TOTAL. Quantidade: D1_QUANT.	D1_FILIAL, D1_DOC, D1_SERIE, D1_FORNECE, D1_LOJA, D1_COD, D1_QUANT, D1_TOTAL, D1_DTDIGIT, D1_TES, D1_NATUREZ, D1_PEDIDO, D1_ITEMPC, D1_CC, D1_CF
SF2 / SD2	Usadas na devolução ao fornecedor (F2_TIPO='D').	F2_CLIENTE, F2_LOJA, F2_TIPO · D2_CLIENTE, D2_TOTAL, D2_NFORI, D2_SERIORI, D2_ITEMORI
SA2	Fornecedores.	A2_COD, A2_LOJA, A2_NOME, A2_NREDUZ, A2_CGC
SB1 / SBM	Produtos e grupos de produto.	B1_COD, B1_DESC, B1_GRUPO, B1_UM · BM_GRUPO, BM_DESC
SC7	Pedidos de compra.	C7_NUM, C7_ITEM, C7_FORNECE, C7_PRODUTO, C7_QUANT, C7_PRECO, C7_TOTAL, C7_EMISSAO, C7_DATPRF
CTT / SED / SF4	Centro de custo, natureza e TES.	CTT_CUSTO, CTT_DESC01 · ED_CODIGO, ED_DESCRIC · F4_CODIGO, F4_TEXTO, F4_ESTOQUE, F4_DUPLIC

JOINS PADRÃO

```
SD1 → SF1: D1_FILIAL=F1_FILIAL AND D1_DOC=F1_DOC AND D1_SERIE=F1_SERIE AND D1_FORNECE=F1_FORNECE
SF1 → SA2: F1_FORNECE=A2_COD AND F1_LOJA=A2_LOJA
SD1 → SB1: D1_COD=B1_COD          SB1 → SBM: B1_GRUPO=BM_GRUPO
SD1 → SC7: D1_PEDIDO=C7_NUM AND D1_ITEMPC=C7_ITEM
SD1 → CTT: D1_CC=CTT_CUSTO        SD1 → SED: D1_NATUREZ=ED_CODIGO
SD1 → SF4: D1_TES=F4_CODIGO
```

F1_TIPO = 'N' obrigatório

N=Normal (compra real), D=Devolução ao fornecedor, C=Complementar (correção de valor/frete/impostos), B=Beneficiamento. Só o tipo 'N' representa compra efetiva — validado em tempo de execução.

Devolução usa SF2/SD2, nunca SF4/TES

Para devolução ao fornecedor, o SQL usa SF2/SD2 com F2_TIPO='D' — nunca SF4 ou CASE em SD1. O código do fornecedor fica gravado em F2_CLIENTE/D2_CLIENTE nesse cenário. Devoluções não entram por padrão, só se o usuário pedir explicitamente.

Nunca somar SF1.F1_VALBRUT com JOIN em SD1

SD1 é tabela de itens — cada nota tem N linhas, o que multiplicaria o valor bruto do cabeçalho por N. Métrica de item usa sempre SD1.D1_TOTAL.

F4_ESTOQUE e F4_DUPLIC conforme a pergunta

Pergunta sobre estoque exige F4_ESTOQUE='S'; pergunta sobre financeiro/duplicata/contas a pagar exige F4_DUPLIC='S'. Validado em tempo de execução.

Índices/chaves

O spec não cita nomes de índice físico do Protheus — apenas as chaves compostas de junção acima (Filial+Doc+Série+Fornecedor+Loja para SD1↔SF1).

7.8 Dicionário de Dados — Faturamento

Tabelas, campos e joins que o spec do módulo Faturamento conhece e usa para gerar SQL. Cobre notas de saída, devoluções de venda e faturamento por dimensão (cliente, produto, vendedor).

TABELA	O QUE É	CAMPOS PRINCIPAIS
SF2	Cabeçalho de NF de saída. Métrica geral: F2_VALBRUT (quando não precisa de item).	F2_FILIAL, F2_DOC, F2_SERIE, F2_CLIENTE, F2_LOJA, F2_EMISSAO, F2_TIPO, F2_VALBRUT, F2_VALMERC, F2_VALFAT, F2_VEND1
SD2	Itens de NF de saída. Métrica de item: D2_TOTAL. Quantidade: D2_QUANT.	D2_FILIAL, D2_DOC, D2_SERIE, D2_CLIENTE, D2_LOJA, D2_COD, D2_QUANT, D2_TOTAL, D2_TES, D2_CF, D2_CCUSTO
SF1 / SD1	Usadas na devolução de venda (F1_TIPO= 'D'). Valor: D1_TOTAL.	F1_FORNECE, F1_LOJA, F1_DTDIGIT, F1_TIPO · D1_FORNECE, D1_TOTAL
SA1 / SA3	Clientes e vendedores.	A1_COD, A1_LOJA, A1_NOME, A1_NREDUZ · A3_COD, A3_NOME

TABELA	O QUE É	CAMPOS PRINCIPAIS
SB1 / SBM	Produtos e grupos de produto.	B1_COD, B1_DESC, B1_GRUPO · BM_GRUPO, BM_DESC
SF4 / CTT	TES (tipo de entrada/saída) e centro de custo.	F4_CODIGO, F4_TEXTO, F4_ESTOQUE, F4_DUPLIC, F4_CF · CTT_CUSTO, CTT_DESC01

JOINS PADRÃO

```
SD2 → SF2: D2_FILIAL=F2_FILIAL AND D2_DOC=F2_DOC AND D2_SERIE=F2_SERIE AND D2_CLIENTE=F2_CLIENTE
SF2 → SA1: F2_CLIENTE=A1_COD AND F2_LOJA=A1_LOJA          SF2 → SA3: F2_VEND1=A3_COD
SD2 → SB1: D2_COD=B1_COD          SB1 → SBM: B1_GRUPO=BM_GRUPO
SD2 → SF4: D2_TES=F4_CODIGO      SD2 → CTT: D2_CCUSTO=CTT_CUSTO
SD1 → SF1 (devolução): D1_FILIAL=F1_FILIAL AND D1_DOC=F1_DOC AND D1_SERIE=F1_SERIE AND D1_CLIENTE=F1_CLIENTE
SF1 → SA1 (devolução): F1_FORNECE=A1_COD AND F1_LOJA=A1_LOJA (código do cliente fica em F1_CLIENTE)
```

F2_TIPO = 'N' obrigatório

N=Normal (venda real), D=Devolução de cliente, B=Beneficiamento, I/P=Complementar de impostos. Só 'N' representa receita de venda — validado em tempo de execução, e "F2_TIPO = 'I'" é padrão proibido.

Devolução usa SF1/SD1 com UNION ALL, nunca SF4/CASE em SD2

Para venda líquida de devoluções, o SQL usa subquery UNION ALL com SF1/SD1 (F1_TIPO='D') — nunca SF4/TES ou CASE em SD2. Devoluções só entram se o usuário pedir explicitamente ("líquido", "abatendo").

Nunca somar SF2.F2_VALBRUT com JOIN em SD2

SD2 é tabela de itens (N linhas por nota) — multiplicaria o valor bruto do cabeçalho. Quando SD2 está no FROM/JOIN, a métrica correta é SUM(SD2.D2_TOTAL) ou SUM(SD2.D2_QUANT).

CFOP (D2_CF) filtra remessas e entrega futura

CF 59%/60% = simples remessa/transferência, excluído por padrão da receita. CF = 5117 = entrega futura/nota mãe, tratado separadamente conforme a pergunta.

Média exige subquery em duas camadas

AVG(SF2.F2_VALBRUT) direto calcula ticket médio por nota, não faturamento médio por período — proibido. O cálculo correto agrupa por período numa subquery e tira a média na camada externa.

Índices/chaves

Não há índice físico citado no spec — apenas a chave composta de junção (Filial+Doc+Série+Cliente+Loja para SD2↔SF2).

7.9 Dicionário de Dados — Financeiro

Tabelas, campos e joins do módulo Financeiro: contas a pagar, contas a receber, saldo bancário e fluxo de caixa projetado. O modelo de baixas (FK1/FK2 ou SE5) varia por tenant — veja a nota mais abaixo.

TABELA	O QUE É	CAMPOS PRINCIPAIS
SE1	Contas a receber. E1_SALDO=0 = título já recebido.	E1_CLIENTE, E1_LOJA, E1_VENCTO, E1_VENCREA, E1_VALOR, E1_SALDO, E1_NATUREZ, E1_SITUACAO, E1_VEND1
SE2	Contas a pagar. E2_SALDO=0 = título já pago.	E2_FORNECE, E2_LOJA, E2_VENCTO, E2_VENCREA, E2_VALOR, E2_SALDO, E2_NATUREZ, E2_SITUACAO
SE5	Movimentos/baixas financeiras (modelo legado). E5_RECPEG: R=recebimento, P=pagamento.	E5_DATA, E5_VALOR, E5_CLIFOR, E5_LOJA, E5_TIPO, E5_SITUACAO
FK1 / FK2	Família moderna de baixas (usada no lugar de SE5 conforme configuração do tenant).	FK1_DATA, FK1_VALOR · FK2_DATA, FK2_VALOR
SE8	Saldo bancário. E8_SALATUA = saldo na data E8_DTSALAT. Cada conta tem múltiplas linhas, uma por data.	E8_BANCO, E8_AGENCIA, E8_CONTA, E8_DTSALAT, E8_SALATUA
SA1 / SA2 / SA6	Clientes, fornecedores e contas bancárias.	A1_COD/A1_NOME · A2_COD/A2_NOME · A6_COD, A6_AGENCIA, A6_NUMCON, A6_BLOCKED
SED	Natureza financeira.	ED_CODIGO, ED_DESCRIC

JOINS PADRÃO

```
SE1 → SA1: E1_CLIENTE=A1_COD AND E1_LOJA=A1_LOJA      SE2 → SA2: E2_FORNECE=A2_COD AND E2_LOJA=A2_LOJA
SE1 → SED: E1_NATUREZ=ED_CODIGO                        SE2 → SED: E2_NATUREZ=ED_CODIGO
SE8 → SA6: E8_BANCO=A6_COD AND E8_AGENCIA=A6_AGENCIA AND E8_CONTA=A6_NUMCON
```

Baixa de recebimento — tenant com FK1:

```
FK1_FILIAL=E1_FILIAL AND FK1_PREFIXO=E1_PREFIXO AND FK1_NUM=E1_NUM AND FK1_PARCELA=E1_PARCELA
```

Baixa de recebimento — tenant legado (SE5):

```
E5_FILIAL=E1_FILIAL AND E5_PREFIXO=E1_PREFIXO AND E5_NUMERO=E1_NUM AND E5_PARCELA=E1_PARCELA
AND E5_TIPO=E1_TIPO AND E5_CLIFOR=E1_CLIENTE AND E5_LOJA=E1_LOJA AND E5_RECPEG='R' AND
(mesmo padrão para SE2/FK2/SE5 com E5_RECPEG='P')
```

⚠ SE1 e SE2 nunca são unidas por JOIN direto — são carteiras independentes (receber x pagar); combinar totais exige UNION ALL, nunca JOIN.

Modelo de baixa é condicional por tenant

Cada empresa usa FK1/FK2 ou SE5 para representar baixas — nunca ambos. O spec escolhe automaticamente com base na configuração salva (modeloBaixasReceber/modeloBaixasPagar). Ver [Conexões ERP](#).

Sempre usar E1_VENCREA/E2_VENCREA, nunca VENCTO

VENCTO é o vencimento nominal; VENCREA já ajusta sábado/domingo/feriado. Filtros de data de vencimento são proibidos de usar E1_VENCTO/E2_VENCTO.

Saldo bancário puro usa somente SE8 + SA6

Nunca inclui SE1/SE2/SE5/FK. Exige filtro de posição mais recente por conta (ROW_NUMBER ou MAX(E8_DTSALAT)) para não somar saldos duplicados de datas diferentes. Bancos com A6_BLOCKED='1' são sempre excluídos.

Fluxo de caixa projetado nunca usa SE5/FK

Projeção usa E1_SALDO>0 e E2_SALDO>0 (títulos em aberto), nunca movimentos já baixados. Proibido JOIN entre SE8 e SE1/SE2, e proibido FULL OUTER JOIN (não suportado no ambiente).

Tabelas sem uso documentado: FK5, FK6, FK7, FKA, FKB

Aparecem na lista de tabelas e campos essenciais do spec, mas não há explicação de uso nos fragmentos analisados — tratadas como reserva para modelos de fluxo de caixa mais avançados.

7.10 Dicionário de Dados — Comissão

Tabelas, campos e joins do módulo Comissão: apuração por vendedor e cliente, com controle de acesso restrito por número de WhatsApp.

TABELA	O QUE É	CAMPOS PRINCIPAIS
SE3	Comissões. Métrica: E3_COMIS. Valor base/venda: E3_BASE.	E3_VEND, E3_VENDED, E3_CLIENT, E3_LOJA, E3_VENCTO, E3_DATA, E3_STATUS, E3_COMIS, E3_BASE, E3_PERCCOM
SA3 / SA1	Vendedores e clientes.	A3_COD, A3_NOME · A1_COD, A1_LOJA, A1_NOME
SE2 / SE5	Usadas apenas para comissão paga/realizada (provisão e baixa financeira), quando os campos existirem no ambiente.	E2_NUM, E2_PARCELA, E2_TIPO · E5_DATA, E5_VALOR, E5_CLIFOR

JOINS PADRÃO

SE3 → SA3: E3_VEND=A3_COD

SE3 → SA1: E3_CLIENT=A1_COD AND E3_LOJA=A1_LOJA

Pagamento real (apenas quando campos existirem):

SE3 → SE2: E2_FORNECE=E3_VEND (ou E3_VENDED) AND E2_NUM=E3_NUM AND E2_PARCELA=E3_PARCELA

SE2 → SE5: E5_CLIFOR=E2_FORNECE AND E5_NUMERO=E2_NUM AND E5_PARCELA=E2_PARCELA

! **Controle de identidade obrigatório:** todo número de WhatsApp é resolvido em "Números Autorizados" antes de qualquer SQL. Gestor vê tudo; vendedor só vê a própria comissão (filtro fixo em E3_VEND/E3_VENDED, nunca em SA3.A3_COD); número não cadastrado bloqueia a execução. O sistema nunca revela nome ou código de outro vendedor.

E3_STATUS não indica pagamento

Comissão em aberto/pendente é identificada por E3_DATA vazio; paga/realizada por E3_DATA preenchido. E3_STATUS tem outro propósito e nunca deve ser usado como indicador de pago/aberto.

Média exige subquery em duas camadas

AVG(E3_COMIS) ou AVG(E3_BASE) direto com GROUP BY calcula o ticket médio por lançamento, não a média entre períodos — mesmo padrão de proibição do Faturamento/Compras. AVG(SUM(...)) na mesma camada é inválido no SQL Server.

Índices/chaves

Nenhum índice físico citado. Chave composta condicional SE3↔SE2↔SE5 usa Filial+Num+Parcela+Tipo+Prefixo "quando os campos existirem" — o schema de comissão varia mais entre tenants que os demais módulos.

7.11 Dicionário de Dados — Estoque

Diferente dos 4 dicionários anteriores, o spec de Estoque existe no código de forma completa (dicionário de dados, classificador de intenção, handler de SQL, middleware próprio), mas **não é semeado automaticamente** como intenção dinâmica padrão na inicialização — ver [6.1 — Módulos](#) para essa distinção.

Termos ativadores próprios

O classificador reconhece termos como "estoque", "saldo em estoque", "requisição", "transferência de estoque", "curva ABC", "giro de estoque" — vocabulário específico do módulo, distinto dos outros 4.

Rede de segurança via spec genérico

Perguntas de estoque que a intenção dedicada não capturar caem no spec genérico do sistema, que atua como rede de segurança para não deixar a pergunta sem resposta — mas isso significa que o comportamento pode ser menos consistente do que nos 4 módulos plenamente equiparados.

⚠ Se uma pergunta de estoque se comportar de forma inconsistente (às vezes classifica certo, às vezes cai no genérico), isso é esperado dado o estado atual do módulo — não é necessariamente um bug de sinônimo ou normalização faltando.

8


Aprendizado NL-SQL

Cache e reuso semântico de SQL — reduz custo de IA sem perder precisão

8.1 O que é o Aprendizado NL-SQL

Cada pergunta que passa pelo Text-to-SQL dinâmico ([Fase 7](#)) gera uma chamada à IA para produzir o SQL. O Aprendizado NL-SQL é um subsistema de **cache e reuso semântico**: quando uma pergunta nova é muito parecida (por significado, não por texto exato) com uma já respondida com sucesso, o sistema pode reutilizar o SQL já validado em vez de gerar um novo pela IA — reduzindo custo e latência sem abrir mão de precisão.

DIAGRAMA 8 — PIPELINE DO APRENDIZADO NL-SQL



Reuso por similaridade semântica (embeddings)

Perguntas são comparadas por significado via embeddings, não por texto literal — "faturamento de abril" e "quanto vendemos em abril" podem ser reconhecidas como equivalentes mesmo com palavras diferentes.

Shadow Mode — grava sem servir

Antes de um candidato a reuso ser efetivamente servido ao usuário, o sistema pode operar em modo sombra: grava o candidato e compara com o que a IA geraria, sem impactar a resposta real — ver [8.3](#).

Promoção controlada por políticas e calibração

Um candidato só passa a ser servido automaticamente depois de calibrado — o sistema mede a taxa de acerto por módulo/faixa de score antes de confiar nele em produção.

Kill switches por variável de ambiente

O reuso semântico, o shadow mode e o ranking por embeddings podem ser desativados independentemente via variáveis de ambiente — permite desligar rapidamente se o comportamento não estiver satisfatório, sem precisar reverter código.

i Este subsistema é complementar ao pipeline de 8 passos da Fase 7 — ele decide se vale a pena pular a geração de SQL pela IA, não substitui nenhum dos passos quando a IA é de fato chamada.

8.2 Saúde do Aprendizado

Tela admin-nlsql-saude.html — painel geral de saúde do subsistema: volume de reuso, taxa de acerto, e alertas quando o comportamento foge do esperado.

admin-nlsql-saude.html — Saúde do Aprendizado

IA

IA Command / Saude do Aprendizado NL-SQL - Administrador

Ajuda

J2A TESTE

APRENDIZADO NL-SQL

Saude do Aprendizado 746 consulta(s), 5 empresa(s) no escopo

Atualizar

dd/mm/aaaa

dd/mm/aaaa

Todos os módulos

100 recentes

Aplicar

CONSULTAS

746

Sucesso: 80.7%

DATASET

42

Usor: 5.6%

ECONOMIA LLM

188

Cache/reuso: 25.2%

CACHE CONFIÁVEL

3803

Pendentes: 1205

EMBEDDINGS OK

0

Pendentes: 263

SHADOW PRECISION

3.0%

Amostra: 436

POR ORIGEM DE EXECUCAO

ORIGEM	TOTAL	SUCESSO	ERRO	TEMPO MEDIO
SQL direto IA	391	328	60	18.2s
agendamento_sql_fixado	238	53	3.2s	
Dataset semantico	41	33	8	4.8s
Nao informado	23	3	0	3.1s

POR MODULO

MODULO	TOTAL	DATASET	CACHE	BLOQUEIOS
faturamento	516	36	26	0
chamados	119	6	0	0
compras	54	0	1	0
financeiro	44	0	1	0
estoque	13	0	0	0

POR EMPRESA PERMITIDA

EMPRESA	TOTAL	DATASET	CACHE	TEMPO MEDIO
CAIEIRA #4	376	0	18	9.9s
J2A Consultoria #1	175	42	4	3.9s
Plantivo #5	155	0	2	20.3s
C3i Systems #2	25	0	4	11.3s

SHADOW MODE RECENTE

DATA	EMPRESA	MODULO	RESULTADO	SCORE
14/09/2026, 11:54:56	Plantivo	faturamento	Mismatch	0.940
14/09/2026, 11:39:39	Plantivo	faturamento	Mismatch	0.940
08/09/2026, 14:01:08	Plantivo	faturamento	Mismatch	0.880
08/09/2026,	Plantivo	faturamento	Mismatch	1.000

Usabilidade

Use como primeiro ponto de checagem antes de investigar uma resposta suspeita: se o volume de reuso disparou ou a taxa de acerto caiu, é sinal de que vale revisar a calibração antes de mexer em sinônimos ou specs.

8.3 Shadow Mode

Tela `admin-nlsql-shadow.html` — mostra os candidatos a reuso gravados em modo sombra: o que o sistema teria servido por reuso vs. o que a IA gerou de fato, lado a lado, sem que o usuário tenha percebido a diferença.

Grava sem servir

Em shadow mode, o candidato de reuso nunca chega ao usuário — a resposta real sempre vem da IA. O candidato é só registrado para comparação posterior.

Usabilidade

Use esta tela para decidir se um padrão de pergunta está maduro o suficiente para sair do shadow mode e passar a ser servido de fato — sem esse período de observação, promover um candidato cedo demais arrisca servir SQL levemente errado com confiança de "já validado".

8.4 Calibração e Políticas de Decisão Automática

Duas telas complementares que controlam quando um candidato de reuso passa a ser servido automaticamente.

Calibração (`admin-nlsql-calibracao.html`)

Mede a precisão real do reuso por módulo e por faixa de score de similaridade — não é a mesma faixa de confiança para todos os módulos, já que a variabilidade das perguntas difere entre Compras, Faturamento, Financeiro e Comissão.

Decisões Automáticas / Políticas (`admin-nlsql-politicas.html`)

Define as regras de promoção: a partir de qual score de similaridade e qual taxa de acerto calibrada um candidato passa a ser servido sem passar pela IA.

8.5 Embeddings e Backfill

Duas telas de manutenção do índice de similaridade semântica usado pelo reuso.

Embeddings ([admin-nlsql-embeddings.html](#))

Painel do índice de embeddings usado para comparar perguntas por significado — status de geração, volume indexado.

Backfill ([admin-nlsql-backfill.html](#))

Processa perguntas históricas que ainda não têm embedding gerado, para que passem a ser candidatas a reuso em perguntas futuras semelhantes.

9

Auditoria e Monitoramento

Rastreie cada execução, interpretação e ação no sistema

9.1 Execuções — Histórico de respostas ao ERP

Registra cada execução completa: da mensagem recebida até a resposta enviada. Inclui a intenção identificada, o dataset ou pipeline executado, o resultado do ERP e o tempo total. É o log operacional principal do sistema.

[admin-execucoes.html](#) — Execuções

IA

IA Command > Histórico de Interpretações - Administrador

Empresa Teste

ADMINISTRACAO

Histórico de Interpretações 15 de 15 registro(s)

Ajuda Limpar log Atualizar

+ Mostrar agrupamento Sem agrupamento ativo

	DATA/HORA	CELULAR	CANAL	PERGUNTA	RESPOSTA	INTENCAO
			Todos			
	21/08/2026 08:53:57	(65) 99999-0001	Chat	Faturamento do mes com nome cliente, data , nota fiscal e produto.	Nao encontrei faturamento para essa consulta.	faturamento
	20/08/2026 10:19:04	(65) 99999-0002	Chat	Faturamento do mes com nome cliente, data , nota fiscal e produto.	Nao encontrei faturamento para essa consulta.	faturamento
	20/08/2026 10:11:09	(65) 99999-0003	Chat	Faturamento do mes com nome cliente, data , nota fiscal e produto.	Nao encontrei faturamento para essa consulta.	faturamento
	20/08/2026 09:06:17	(65) 99999-0004	Chat	Faturamento do mes com nome cliente, data , nota fiscal e produto.	Tivemos uma inconsistencia ao interpretar sua consulta de faturamento. Por favor, reformule a pergunta e tente novamente.	faturamento
	18/08/2026 07:18:09	(65) 99999-0005	WhatsApp	bom dia lista chamados em atraso	Bom dia! Vou verificar a lista de chamados em atraso para você. Um momento, por favor. [Realizando a consulta...] Aqui estão os chamado...	dialogo_cor
	17/08/2026 10:51:54	(65) 99999-0006	WhatsApp	Qual o faturamento do mês 08	*Empresa Teste* Nao encontrei faturamento para essa consulta. *Empresa Cliente B* *Faturamento --> Qual o faturamento do mês 0...	faturamento
	17/08/2026 10:51:51	(65) 99999-0007	WhatsApp	Qual o faturamento do mês 08	Nao encontrei faturamento para essa consulta.	faturamento
	14/08/2026 17:10:32	(65) 99999-0008	Chat	RESET	? Fiquei em duvida sobre qual indicador, periodo ou detalhe voce quer consultar.	desconhecido
	14/08/2026 17:06:46	(65) 99999-0009	Chat	Contas a pagar da semana	*Financeiro --> Contas a pagar da semana* *Por Vencimento, No. Titulo, Fornecedor* 1. Vencimento 10/08/2026 No. Titulo 000040788 ...	financeiro_d

Contrato semântico completo

Campos retornados pelo orquestrador: modulo, periodo (data_ini/data_fim), filtros, agrupamentos, operacao (pagar/receber), carteira, estado (aberto/vencido/liquidado), fluxoTipo, herdou_contexto.

Provider utilizado

Qual provedor de IA respondeu (Groq, OpenAI, etc.) e o modelo específico. Útil para diagnóstico quando a cascata de fallback foi ativada.

Usabilidade

Use quando uma execução retornou resultado inesperado. Compare o contrato semântico com o que o usuário quis dizer — se a IA interpretou errado, verifique sinônimos ou adicione um guardrail.

9.3 Log de Módulos — Rastreamento por pipeline

Log detalhado de execução por módulo dinâmico (compras, faturamento, financeiro, comissão). Registra cada passo do pipeline Text-to-SQL com timestamps, dados intermediários e erros por etapa. Complementa o log geral de consultas SQL com o contexto do módulo.

Log de Módulos

Módulo
Faturamento

Período
Hoje

Filtrar

HORA	PASSO	STATUS	DETALHE
14:32:18	Contrato Temporal	OK	01/04–30/04/2026
14:32:19	Query Plan	OK	tabela: SD2, agrup: SB1
14:32:20	Geração SQL	OK	45 tokens · 1 join
14:32:20	Validação SX3	Aviso	D2_CODPROD ignorado (IA-first)

Objetivo

Diferente do log geral de consultas, este log mostra os passos intermediários do pipeline — útil para identificar em qual passo específico uma consulta falhou ou produziu resultado inesperado.


Avisos SX3

Logs com "Aviso SX3 ignorado por diretriz IA-first" indicam que a IA usou um campo que não está no dicionário. Verifique o resultado — se correto, ignore. Se errado, adicione o campo correto como sinônimo ou ajuste o prompt.

9.4 Auditoria Geral — Rastreabilidade de todas as ações

Registra todas as ações administrativas: criação, edição e exclusão de módulos, datasets, intenções, sinônimos, conexões e configurações de IA. Cada ação inclui usuário, IP, data/hora e conteúdo alterado.

admin-auditoria.html — Auditoria Geral



Filtros

Por período, usuário, tipo de ação (criar/editar/excluir) e entidade afetada. Use para rastrear quem alterou uma configuração que causou mudança de comportamento.

Conteúdo alterado

Para edições, a auditoria registra o valor anterior e o novo valor de cada campo alterado. Permite reverter uma mudança manualmente se necessário.

⚠ Existem dois logs de auditoria separados. Esta tela mostra apenas a auditoria interna do IA Command (módulos, datasets, intenções, sinônimos, conexões). Ações de **login, logout e troca de empresa/sistema** ficam registradas num log central do IAHub, fora do IA Command — se precisar rastrear "quem trocou de empresa" ou "quem fez login", procure na auditoria do IAHub, não aqui.

9.5 Feedback Técnico da IA

Tela `admin-spec-feedback.html` — registra feedback técnico sobre o comportamento da IA em execuções específicas, complementando as demais telas de auditoria com um canal voltado à qualidade do spec/IA-OWNER,

não só ao rastreamento de execuções.

10

Checklist de Implantação

Ordem recomendada e diagnóstico de problemas comuns

10.1 Ordem recomendada de configuração

Siga esta sequência para evitar retrabalho. Cada etapa depende da anterior estar funcionando.

- 1 **Configurar IA (config-ia.html)** — Informe o provedor e a chave de API. Teste a conexão. Sem isso, apenas bypass funciona.
- 2 **Decidir Agente Local ou Conexão Direta** — Para Agente Local, instale a API Python no servidor do cliente (ver [Instalando o Agente Local](#)) e gere/configure o token na nuvem. Para Conexão Direta, siga o próximo passo.
- 3 **Configurar Conexão ERP (config-conexoes.html)** — Se optou por Conexão Direta, adicione a conexão ao banco Protheus. Teste a conectividade com o botão de teste.
- 4 **Ativar Criptografia AES-256-GCM (opcional)** — Se usar Agente Local, gere a chave em Configurar IA ou no painel local do agente e cole no outro lado, para criptografar o endpoint `/execute`.
- 5 **Configurar Middleware (config-middleware-protheus.html)** — Revise o ROWCOUNT máximo e confirme que o bloqueio DDL/DML está ativo.
- 6 **Cadastrar Canal WhatsApp (admin-canais-whatsapp.html)** — Adicione o número do canal e vincule à empresa.
- 7 **Autenticar no Monitor (monitor.html)** — Escaneie o QR Code com o celular do número configurado.
- 8 **Configurar Números Autorizados (admin-numeros-whatsapp.html)** — Adicione os números que podem fazer consultas. Deixe vazio para aceitar qualquer número (somente em testes).
- 9 **Testar módulos dinâmicos** — Envie uma pergunta de teste pelo WhatsApp: "faturamento do mês". Verifique em Execuções se a intenção foi classificada corretamente.
- 10 **Consultar SX2/SX3 (admin-protheus-sx2/sx3.html)** — Verifique quais tabelas e campos estão disponíveis para confirmar que o Text-to-SQL tem acesso ao esquema correto.
- 11 **Adicionar Sinônimos (admin-sinonimos.html)** — Após os primeiros dias de uso, identifique termos não reconhecidos no histórico de mensagens e adicione-os.
- 12 **Configurar Diálogos (admin-dialogos.html)** — Adicione respostas para saudações e perguntas sobre o sistema que não sejam consultas ERP.
- 13 **Criar Datasets manuais (admin-datasets.html)** — Para consultas frequentes e estáveis que não precisam de Text-to-SQL, crie datasets com SQL fixo parametrizado.

- 14 **Criar Perguntas Agendadas (admin-agendamento.html)** — Opcional. Com números autorizados já cadastrados, crie jobs para enviar relatórios recorrentes automaticamente (ver [Fase 5 — Agendamento de Perguntas](#)).
- 15 **Monitorar Auditoria e Logs** — Revise execuções, interpretações e log de consultas periodicamente para identificar oportunidades de melhoria.

✓ Os módulos **compras_dinamico**, **faturamento_dinamico**, **financeiro_dinamico** e **comissao_dinamico** são criados automaticamente na inicialização do sistema — não é necessário cadastrá-los. **Estoque** é um 5º módulo dinâmico, mas não é semeado automaticamente — ver [6.1](#).

10.2 Problemas comuns e diagnóstico

SINTOMA	CAUSA PROVÁVEL	COMO RESOLVER
"Não consegui entender sua pergunta"	Confiança da classificação baixa (<0,85 para nova conversa)	Verifique Interpretações para ver o contrato gerado. Adicione sinônimos para os termos da mensagem.
Resultado retorna 0 linhas	Filtro de período ou entidade muito restritivo	Verifique o SQL gerado em Log de Consultas. Em conexões LOBO_GUARA, confirme também se o escopo de empresa foi resolvido corretamente (ver 7.2).
Canal WhatsApp desconectado	Sessão expirou ou telefone ficou offline	Abra o Monitor e escaneie o QR Code novamente.
Erro "Tabela não encontrada"	Sufixo de empresa incorreto no nome da tabela	Consulte SX2 para ver o nome físico correto da tabela (ex: SA1010 vs SA1020).
IA usa módulo errado	Termo ambíguo interpretado pelo módulo errado	Adicione o termo como sinônimo apontando para o módulo correto, ou configure um guardrail.
Resposta muito longa / truncada	ROWCOUNT alto ou muitos agrupamentos	Reduza o ROWCOUNT no Middleware. Instrua usuários a adicionar "top 10" às perguntas.
Erro "DDL/DML bloqueado"	IA gerou SQL com UPDATE/DELETE	Normal — o middleware bloqueou corretamente. Verifique o prompt da pergunta que causou isso em Log de Consultas.
Contexto multi-turn não herda	Intervalo entre mensagens > 10 minutos	O TTL de 10 min expirou — normal. O usuário precisa repetir o contexto na nova mensagem.

SINTOMA	CAUSA PROVÁVEL	COMO RESOLVER
Módulo dinâmico não aparece nas intenções	Inicialização não criou os módulos automaticamente	Reinicie o servidor IA Command — os módulos <code>_dinamico</code> são criados na inicialização se não existirem.
Chave de IA inválida	Chave expirou ou foi revogada	Acesse Configurar IA, atualize a chave e use Testar conexão para validar.
"Falha ao descriptografar resposta do Agente Local"	Chave AES-256-GCM diferente entre a nuvem e o painel local do agente	Confira se a chave do painel local é exatamente igual à chave salva em Configurar IA. Se não bater, gere uma nova chave em um dos lados e cole no outro.
"Criptografia obrigatória para /execute" (HTTP 426)	Agente com <code>CRYPTO_REQUIRED=true</code> , mas a nuvem está enviando sem criptografia	Ative a criptografia em Configurar IA → Agente Local, ou desative <code>CRYPTO_REQUIRED</code> no <code>.env</code> se a criptografia ainda não deve ser obrigatória.
Agente Local não responde ao teste de conexão	Serviço parado, firewall bloqueando a porta 8765, ou URL/token incorretos	Verifique <code>nssm status IACommand-Agente</code> no servidor do cliente, confirme que a porta está acessível pela nuvem e revise URL/token em Configurar IA.
Resultado mistura dados de duas empresas jurídicas (conexão LOBO_GUARA)	Uma segunda empresa jurídica do mesmo grupo Protheus foi vinculada ao IA Command e a pergunta não menciona filial/empresa explicitamente — comportamento fail-open por design	Ver 7.2 — LOBO_GUARA vs. Tradicional . Verifique quantas empresas têm vínculo explícito configurado para a conexão; oriente o usuário a mencionar a empresa/filial na pergunta.
SQL bloqueado com erro de guard LOBO_GUARA	O guard de escopo de empresa recusou aplicar o filtro por inconsistência nos dados de vínculo	Verifique <code>protheus_company_tree</code> da conexão — cada empresa jurídica precisa de vínculo explícito válido para ser elegível na resolução de escopo.
Vendedor/cliente não vê os próprios dados, ou vê dados de outra pessoa	Guard de identidade (vendedor, cliente ou aprovador) não encontrou o número de WhatsApp em Números Autorizados, ou o número está vinculado ao código ERP errado	Ver 7.3 — Guards de Identidade . Confirme o cadastro do número em Números Autorizados e o código ERP vinculado a ele.

i Para diagnósticos avançados, habilite o modo debug nas variáveis de ambiente do servidor. Os logs detalhados do orquestrador e dos providers ficam no console do processo Node.js.